



Universidade Federal da Bahia
Instituto de Computação

Programa de Pós-Graduação em Ciência da Computação

**RECADEMY - UM MODELO
MULTIFATORIAL PARA RECOMENDAÇÃO
PERSONALIZADA DE ARTIGOS
CIENTÍFICOS**

Lucas França Freitas

QUALIFICAÇÃO DE MESTRADO

Salvador
14 de agosto de 2026

LUCAS FRANÇA FREITAS

**RECADEMY - UM MODELO MULTIFATORIAL PARA
RECOMENDAÇÃO PERSONALIZADA DE ARTIGOS
CIENTÍFICOS**

Esta Qualificação de Mestrado foi apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal da Bahia, como requisito parcial para obtenção do grau de Mestre em Ciência da Computação.

Orientador: Prof. Dr. Frederico Araújo Durão

Salvador
14 de agosto de 2026

RESUMO

A busca por referências e trabalhos relacionados constitui uma etapa fundamental da pesquisa científica, porém, demanda elevado esforço dos pesquisadores e consome, em média, quatro horas semanais. O crescimento contínuo do volume de publicações e da diversidade de repositórios científicos torna ainda mais desafiadora a identificação de estudos relevantes e confiáveis, o que resulta no descarte de aproximadamente metade dos trabalhos inicialmente selecionados e compromete a produtividade na revisão da literatura. Diante desse cenário, este estudo propõe o desenvolvimento do *Recademy*, uma plataforma destinada a apoiar as etapas iniciais da pesquisa científica por meio da integração de sistemas de recomendação, da modelagem do perfil do pesquisador e de técnicas de pós-processamento de dados. O sistema emprega processamento de linguagem natural e aprendizado de máquina para analisar o histórico de publicações de pesquisadores e gerar recomendações personalizadas de artigos científicos. Sua arquitetura é composta por uma API responsável pela coleta e pelo processamento dos dados, por integrações com serviços externos de identificação de pesquisadores e com bases bibliográficas, além de uma interface web que disponibiliza recomendações estruturadas aos pesquisadores participantes. A proposta foi avaliada preliminarmente por 27 pesquisadores por meio de um teste cego A/B, no qual o modelo multiplicativo proposto foi comparado ao baseline semântico em seis métricas de ranqueamento (P@K, MRR@K e nDCG@10). Os resultados demonstram que o modelo proposto superou o baseline em cinco das seis métricas avaliadas, alcançando MRR de 0,64 e P@5 de 0,49. Com isso, constata-se que o *Recademy* tem potencial para reduzir o esforço na descoberta de trabalhos relacionados, contribuindo para o avanço dos sistemas de recomendação voltados ao apoio à pesquisa científica.

Palavras-chave: Sistemas de Recomendação; Artigos Científicos; API; Perfil de Pesquisador; Processamento de Linguagem Natural

ABSTRACT

The search for references and related work is a fundamental yet time-consuming task in scientific research, requiring researchers to spend an average of four hours per week identifying relevant literature. The growing number of scientific repositories and publication sources further complicates the verification of the credibility and relevance of retrieved studies, often leading to the rejection of a substantial portion of the collected material and reducing research productivity. To address this challenge, this work proposes designing and developing *Recademy*, a recommendation platform that supports the early stages of the research process by combining personalized recommendation techniques, researcher profile modeling, and data post-processing. The proposed system leverages natural language processing and machine learning to analyze researchers' publication histories and generate personalized recommendations for scientific articles. Its architecture comprises an API for data collection and processing, integrations with external researcher identification and bibliographic services, and a web interface that delivers structured recommendations to participating researchers. Experimental results demonstrate that the multiplicative recommendation model achieved a Mean Reciprocal Rank (MRR) of 0.64 and a Precision at 5 (P@5) of 0.49, outperforming a purely semantic baseline in five of the six evaluation metrics. These findings indicate that *Recademy* has the potential to reduce the effort involved in discovering related work, thereby contributing to the advancement of recommender systems aimed at supporting scientific research.

Keywords: Recommender Systems; Scientific Articles; API; Researcher Profile; Natural Language Processing

SUMÁRIO

Capítulo 1—Introdução	1
1.1 Motivação	2
1.2 Problema	3
1.3 Objetivo da Solução Proposta	4
1.4 Questões de Pesquisa	5
1.5 Metodologia	5
1.6 Estrutura	6
Capítulo 2—Sistemas de Recomendação	7
2.1 Histórico	7
2.2 Conceitos	8
2.3 Tarefas de um Sistema de Recomendação	9
2.4 Técnicas de Recomendação	10
2.4.1 Filtragem Colaborativa	11
2.4.2 Filtragem Baseada em Conteúdo	14
2.4.3 Arquitetura de Sistemas de Recomendação Baseados em Conteúdo	14
2.4.4 Comparação das Técnicas de Recomendação	15
2.4.5 Cálculo de similaridade	16
2.5 Objetivos de Sistemas de Recomendação	18
2.5.1 Acurácia	18
2.6 Sumário	18
Capítulo 3—Sistemas de Recomendação Educacionais	19
3.1 Introdução	19
3.2 Objetos de aprendizagem recomendados	20
3.3 Arquitetura das aplicações	21
3.4 Sistemas de Recomendação para Artigos Científicos	22
3.5 Sumário	23
Capítulo 4—Sistemas de Recomendação de Textos Científicos	25
4.1 Sistemas de recomendação baseados em similaridade textual desestruturada	25
4.2 Sistemas de recomendação de manuscritos científicos	27
4.3 Arquitetura de SR com extração de textos na web	29
4.4 Sumário	31

Capítulo 5—Recademy - Um Sistema de Recomendação de Artigos Científicos	33
5.1 Arquitetura	34
5.2 Perfil do usuário	35
5.3 Modelo do item a ser recomendado	36
5.4 Modelo de recomendação	36
5.5 Interface de Avaliação e Funcionalidades	40
5.6 Recomendação em Ação	40
5.7 Tecnologias	42
5.8 Sumário	42
Capítulo 6—Avaliação Experimental Preliminar	43
6.1 Protocolo de Avaliação	43
6.1.1 Métricas de Avaliação	43
6.2 Avaliação via Experimento Offline	44
6.2.1 Conjunto de Dados	44
6.2.2 Metodologia	45
6.2.3 Métricas de Avaliação	46
6.2.4 Resultados	46
6.3 Experimento Online	48
6.3.1 Metodologia	48
6.3.2 Métricas de Avaliação	49
6.3.3 Conjunto de dados	49
6.3.4 Resultados	50
6.3.5 Discussão	51
6.3.6 Limitações	52
6.4 Análise Contextual com a Literatura	54
6.5 Sumário	55
Capítulo 7—Progresso e Cronograma	57
7.1 Vida Acadêmica	57
7.1.1 Disciplinas Cursadas	57
7.2 Cronograma	59
7.3 Sumário	60
Referências Bibliográficas	61

LISTA DE FIGURAS

2.1	Técnicas de recomendação e suas fontes de conhecimento (BURKE, 2007).	11
2.2	Filtragem Colaborativa baseada em usuários.	12
2.3	Filtragem Colaborativa baseada em itens.	13
2.4	Arquitetura de alto nível de um Sistema de Recomendação Baseado em Conteúdo (LOPS; GEMMIS; SEMERARO, 2011).	15
3.1	Modelo arquitetural para Sistemas de Recomendação (SRs) educacionais.	21
5.1	Diagrama de arquitetura cliente-servidor do sistema Recademy.	35
5.2	Interface web de avaliação do sistema Recademy utilizada no experimento.	40
5.3	Exemplo de item em lista de recomendações gerada pela Interface de Programação de Aplicação (API) Recademy.	41
6.1	Comparativo de métricas dos modelos de <i>scoring</i> no experimento <i>offline</i> ($N = 49$). O número de acertos absolutos (<i>hits</i>) por modelo foi: Base-line Aleatório, 47/49; Baseline Semântico, 42/49; Multiplicativo, 34/49; e Aditivo, 30/49.	47
6.2	Exemplo de recomendação relevante no início da lista.	48
6.3	Métricas de ranqueamento agregadas do Teste A/B ($n = 27$): Lista 1 (Multiplicativo) <i>versus</i> Lista 2 (Baseline Semântico). A média das notas Likert atribuídas (escala 1–5) foi de 2,71 para a Lista 1 e 2,24 para a Lista 2.	50
6.4	Médias do questionário de percepção subjetiva por dimensão ($n = 27$), na escala Likert de 1 a 5. A linha tracejada indica o limiar de relevância (nota 3).	51

LISTA DE SIGLAS

AP	Aprendizado Profundo
API	Interface de Programação de Aplicação
CAPES	Coordenação de Aperfeiçoamento de Pessoal de Nível Superior
DOI	Identificador de Objeto Digital
IA	Inteligência Artificial
IoT	Internet das Coisas
LSTM	Long Short-Term Memory
MAP	<i>Mean Average Precision</i>
MRR	<i>Mean Reciprocal Rank</i>
nDCG	<i>Normalized Discounted Cumulative Gain</i>
PLN	Processamento de Linguagem Natural
RMSE	Root Mean Square Error
SR	Sistema de Recomendação
VPS	Servidor Virtual Privado

INTRODUÇÃO

Internet facilitou significativamente o acesso à informação. O número de dispositivos conectados por usuário único se aproxima de 5 bilhões, totalizando mais de 8 bilhões (KENDE et al., 2022). Esta característica impulsiona a publicização de conteúdos informais em diversas fontes, como blogs e redes sociais, como o Twitter¹, que produz 375 milhões de posts diariamente (PFEFFER et al., 2023), e também expande o acesso a materiais disponibilizados em contextos formais, como os manuscritos científicos, que representam a essência do conhecimento acadêmico, encapsulando descobertas, metodologias e análises que impulsionam o avanço da ciência. Nas últimas décadas, políticas públicas têm sido implementadas nas redes de ensino em nível nacional e regional, com o objetivo de integrar a Internet aos processos educacionais. Diversos projetos obtiveram resultados positivos e aprofundaram o conhecimento sobre o uso da tecnologia no âmbito educacional, apesar das dificuldades enfrentadas quanto à infraestrutura e à capacitação (FALCADE; FALCADE; ABEGG, 2024). A presença desses materiais na *Web* desempenha um papel fundamental na disseminação global do saber, permitindo que pesquisadores compartilhem suas contribuições de forma rápida e acessível. Por meio de plataformas *online*, como repositórios de artigos, periódicos e publicações em licença *Open Access*, o conhecimento científico é disseminado, alcançando uma audiência diversificada e possibilitando a colaboração entre pares em escala global..

Com a popularização da Internet, há uma enorme quantidade de produções científicas de acesso aberto disponíveis em repositórios digitais públicos. Este número não apresenta indícios de queda, com mais de 7,5 milhões de publicações por ano (BROUWER; HOLLENBACH, 2022), além do aumento no número de *journals* científicos ranqueados, que atingiu uma marca próxima de 49 mil periódicos na plataforma Scopus². Apesar da popularização dos elementos de pesquisa científica na *Web* facilitar o acesso ao conteúdo e dinamizar sua difusão, também dificulta a seleção de artigos com base na qualidade do conteúdo e na relevância das publicações.

Sistemas de Recomendação (SRs) desempenham um papel crucial na navegação na *Web* atual, na qual há uma imensa quantidade de recursos disponíveis. Estes sistemas

¹<https://twitter.com>

²<https://www.scopus.com/sources>

auxiliam na filtragem e na personalização do conteúdo, trazendo melhorias tanto para os usuários quanto para as plataformas, aumentando a satisfação dos usuários, o engajamento e a conversão (KIM; CHOI; LI, 2021). Existem diversas aplicações de SR em plataformas on-line, como recomendações de filmes (Cinematch), jogos digitais (Matchbox), música e *podcasts* (BaRT), entre outras, desenvolvidas para os mais variados fins (ROY; DUTTA, 2022). Os itens recomendados servem tanto para consumo quanto para funções (como rotas de navegação) e até mesmo para funções educacionais. No âmbito da educação, os SRs emergiram como assistentes de aprendizado e passaram a ser implementados desde o processo de aprendizagem até a produção de conteúdo. Sua utilização melhora a motivação, o engajamento e a satisfação de seus usuários no desempenho de suas tarefas e responsabilidades. Uma das principais causas destes benefícios é a personalização das experiências em nível individual, possibilitando uma adequação mais natural por parte dos usuários (LAMPROPOULOS, 2023).

No que tange ao uso destes sistemas no âmbito da pesquisa, existem diversas ferramentas disponíveis no mercado que recomendam artigos com base em seus autores, publicações relacionadas ou periódicos, além de trabalhos que utilizam recursos educacionais (MARUYAMA et al., 2023). Há também estudos que empregam mineração de dados aliada a *citation networks* e *collaborative filtering* (STERLING; MONTEMORE, 2022). Apesar dos esforços para a recuperação dos artigos e sua disponibilização, ainda existem lacunas na oferta passiva, de modo que o usuário não precise recorrer à busca por palavras-chave, o que exige ações constantes por parte do usuário final. SRs objetivam a oferta ativa de sugestões que podem auxiliar o processo de descoberta de artigos relacionados à pesquisa em questão, do mesmo modo que reduzem o esforço do pesquisador e aliviam a sobrecarga de informação (PINEDO; LARRAÑAGA; ARRUARTE, 2025), beneficiando-se, dentre outras estratégias, da capacidade de aprender correlações refinadas entre múltiplos elementos por meio de mecanismos de autoatenção, técnica intrinsecamente menos eficiente por meios humanos (JU et al., 2025), e moldando modelos de usuário multifacetados cada vez mais robustos e precisos (ZHANG et al., 2024).

Para desenvolver um sistema de recomendação de publicações científicas disponíveis na *Web*, este trabalho almeja projetar e implementar uma arquitetura de Interface de Programação de Aplicação (API) que gere recomendações com base nas informações fornecidas nos perfis cadastrados pelos usuários nas fontes disponíveis, considerando a relevância dos periódicos, a idade da publicação, entre outros fatores. Além disso, para possibilitar a utilização deste ecossistema de maneira intuitiva, será desenvolvida uma interface web que se comunicará com a API e apresentará os dados de forma legível para o ser humano. c

1.1 MOTIVAÇÃO

A revisão da literatura é de suma importância no processo de pesquisa, pois auxilia na avaliação dos dados coletados das áreas que compõem o trabalho em questão, fornece maior garantia de acesso a informações recentes e fortalece a reputação da pesquisa por meio de suas citações (SNYDER, 2019). Galvão e Ricarte (2019) citam também a otimização de pesquisas já existentes, refinando e melhorando o resultado final do trabalho, a evolução do campo sobre o qual a revisão discorre, evidenciando de novos

aspectos que podem ser analisados ou desenvolvidos através de pesquisa, entre outros. Os pontos citados consistem em soluções práticas para mitigar a complexidade na coleta de trabalhos relacionados, devido ao elevado número de publicações disponíveis. Apesar da existência de diversas plataformas de busca, como PubMed³, Scopus⁴ e Google Scholar⁵, a vantagem da recomendação é apresentar a informação sem necessidade de ação ativa (busca por palavra-chave) e constante por parte do usuário. Os sistemas existentes têm foco extensivo na recomendação de artigos científicos para pesquisadores individuais, com pouca atenção a conjuntos de dados e praticamente nenhuma capacidade de recomendação de *software* (GHANNADRAD et al., 2022). Porém, caso um SR possa unir informações de citações com base em similaridade textual no processo de avaliação dos itens, ele pode ser mais útil para a comunidade científica e produzir recomendações mais relevantes de artigos, conjuntos de dados e *software* para grupos de pesquisadores de maneira eficiente (STERLING; MONTEMORE, 2022).

Um relatório da Elsevier aponta que pesquisadores leem, em média, de 5 a 6 artigos por semana, consumindo cerca de 4 horas na pesquisa desses artigos e cerca de 5 horas na leitura. Apesar do esforço considerável, metade destes trabalhos é descartada por não possuir utilidade para suas pesquisas e referências, desperdiçando valioso tempo que poderia ser utilizado em outras tarefas (ELSEVIER; SCIENCE, 2019).

A pesquisa por trabalhos relacionados configura-se como um processo fundamental na metodologia científica, mas, especialmente na era da sobrecarga de informação e do advento de novas tecnologias, apresenta desafios crescentes quanto à validade e à confiabilidade de seus resultados e representa uma parcela significativa e laboriosa da carga horária do processo de pesquisa (LI et al., 2025). Alguns dos fatores que elevam a complexidade da validação de resultados e da confiabilidade incluem a subjetividade na interpretação de dados, a limitação de recursos, a falta de padronização de processos ou métodos e a qualidade dos recursos estudados (DECLERCQ; POPPEL, 2023).

A adoção de técnicas de Recuperação de Informação, aliadas ao emprego de mecanismos inteligentes de recomendação, pode ser realizada na automatização do processo de busca por este tipo de trabalho, visando à produtividade e à qualidade.

1.2 PROBLEMA

O problema de pesquisa central desta dissertação consiste na insuficiência de mecanismos de recomendação de trabalhos relacionados verdadeiramente integrados ao fluxo de trabalho do pesquisador. Atualmente, a busca por literatura relevante é um processo reativo e fragmentado, realizado fora do ambiente de escrita e de ideação. Esta ausência de ferramentas adequadas manifesta-se por diversos efeitos negativos. Primeiramente, observa-se um notável desperdício de tempo e esforço cognitivo, pois o pesquisador é forçado a alternar constantemente entre seu manuscrito e múltiplas bases de dados, o que interrompe o raciocínio. Em segundo lugar, essa abordagem manual frequentemente resulta na seleção de trabalhos apenas superficialmente relevantes, enfraquecendo a fundamentação teórica

³<https://pubmed.ncbi.nlm.nih.gov>

⁴<https://www.scopus.com>

⁵<https://scholar.google.com>

do estudo. Adicionalmente, nota-se a ausência de ferramentas transparentes que considerem critérios de avaliação de qualidade locais, como a estratificação Qualis-CAPES, amplamente utilizados no contexto brasileiro. Mecanismos de busca frequentemente ignoram essas métricas específicas, o que pode levar o pesquisador a perder estudos de alto valor estratégico e reconhecida qualidade pela comunidade científica nacional. Por fim, a sobrecarga decorrente da necessidade de gerenciar buscas complexas e analisar um volume massivo de resultados pode levar a esgotamento mental e a significativos lapsos de concentração, comprometendo a qualidade e a profundidade da pesquisa em si (MARUYAMA et al., 2023).

A ausência de um SR especializado no âmbito acadêmico acarreta consequências ainda mais profundas, capazes de minar a validade e a inovação de uma pesquisa. A dependência de buscas manuais por palavras-chave pode, inadvertidamente, aprisionar o pesquisador em um ciclo vicioso restrito à terminologia exata empregada na consulta, levando-o a consumir informações desatualizadas ou a reforçar um viés de confirmação, ignorando estudos que apresentem perspectivas contraditórias ou mais recentes. Diante do dilúvio de publicações científicas, a análise manual de conjuntos de dados bibliográficos torna-se ineficiente e humanamente impraticável, resultando em um distanciamento inevitável em relação ao estado da arte e no risco de desenvolver pesquisas redundantes. Grande parte dessa dificuldade decorre da complexidade de traduzir uma linha de pensamento abstrata em um conjunto preciso e eficaz de palavras-chave. Essa lacuna semântica entre a intenção do pesquisador e a linguagem dos sistemas de busca tradicionais reduz drasticamente a probabilidade de recuperar os artigos mais adequados e pertinentes à investigação em curso (HANYURWIMFURA et al., 2015).

Embora os SRs já estejam presentes em alguns repositórios ou índices de artigos, como Google Scholar e ResearchGate, as recomendações produzidas por estas implementações não levam o perfil do pesquisador em consideração. Além disso, exigem que o pesquisador interrompa seu fluxo de trabalho para acessar ativamente a plataforma, segregando o momento da descoberta da escrita, adicionando camadas de complexidade e demandando esforço constante para encontrar trabalhos relacionados em periódicos ou em eventos de alta relevância.

1.3 OBJETIVO DA SOLUÇÃO PROPOSTA

O objetivo deste trabalho é desenvolver um Sistema de Recomendação de artigos científicos, considerando fontes de dados abertos na *Web* e o histórico de publicações do usuário. O sistema deverá operar sem exigir esforço adicional do pesquisador, mantendo, ainda assim, um alto padrão de precisão ao considerar seu perfil e trabalhos recentes, de modo a contribuir positivamente para a produtividade do processo de pesquisa. Os objetivos específicos são:

OE1: Propor uma arquitetura *Web* para desenvolvimento de sistema de recuperação de manuscritos

OE2: Modelar o perfil de usuário a partir do conteúdo de seus trabalhos publicados

OE3: Desenvolver um algoritmo de recomendação baseado no perfil do usuário e implementar a engenharia do sistema

OE4: Validar a aplicabilidade da solução

1.4 QUESTÕES DE PESQUISA

Após discussão dos problemas e objetivos, é possível elaborar o seguinte conjunto de questões:

QP1: Como modelar implicitamente o perfil de preferências do pesquisador a partir de seu histórico acadêmico?

QP2: Qual estratégia de recomendação apresenta maior precisão e melhor alinhamento ao perfil do pesquisador?

QP3: Qual é a melhor forma de disponibilizar as recomendações de maneira integrada ao fluxo de trabalho do pesquisador?

1.5 METODOLOGIA

Este trabalho contempla o desenvolvimento de um SR que se propõe a preencher uma lacuna no mercado, tendo como itens de alta relevância e qualidade na literatura, visando aprimorar as tecnologias no estado da arte.

1. **Revisão da literatura:** A revisão da literatura apresenta diversos trabalhos relacionados que contribuem para melhorias de desempenho, segurança e privacidade dos dados, mas corrobora a hipótese inicial de ausência de um SR que gere recomendações com base em trabalhos recentes e no histórico do pesquisador-utilizador da ferramenta.
2. **Montagem da preferência de um usuário:** Após a análise da literatura, o modelo de usuário foi construído com base nas informações necessárias para gerar recomendações relevantes e de alta qualidade. Dados considerados inicialmente incluíam nomes de funções exercidas na indústria e de cursos superiores; porém, somente publicações no âmbito acadêmico e científico foram mantidas até o final da etapa de montagem.
3. **Design de arquitetura:** Com o modelo de usuário pronto, o próximo passo foi projetar uma arquitetura com foco em desenvolvimento *Web* que atendesse aos requisitos necessários para integrar o SR a pesquisadores por meio da Internet. A solução proposta consiste em uma API *REST* alimentada por um motor de recomendação e acessível via interface web.
4. **Desenvolvimento do modelo de recomendação:** Seguindo as definições estabelecidas nas etapas anteriores, o próximo passo foi a construção do modelo de recomendação, aplicando técnicas e conceitos como **NLP!** (**NLP!**), *word embedding* e *cosine similarity* para alcançar a maior proximidade possível em relação ao modelo do usuário.
5. **Desenvolvimento de uma interface intuitiva para o usuário:** Após finalizar o desenvolvimento da API, o próximo passo foi a construção de uma interface

web de avaliação, por meio da qual os participantes do experimento acessaram as recomendações e submeteram suas avaliações.

6. **Avaliação de resultados:** Com a plataforma disponível, as recomendações foram avaliadas pelos participantes por meio de um formulário estruturado, e as pontuações coletadas foram utilizadas como métricas de precisão e relevância do sistema.

s

1.6 ESTRUTURA

O Capítulo 2 apresenta os conceitos teóricos que fundamentam este trabalho, abordando os principais tipos de SRs, as técnicas de filtragem e os cálculos de similaridade. No Capítulo 3, a discussão é aprofundada no contexto de recomendação de artigos científicos, explorando arquiteturas e objetos de aprendizagem relevantes para este domínio. O Capítulo 4 apresenta e analisa propostas correlatas, subdivididas em temas pertinentes a esta pesquisa e suas respectivas contribuições para o estado da arte. O Capítulo 5 detalha a arquitetura do sistema Recademy, sua estratégia de recomendação e os resultados da implementação. O Capítulo 6 valida a eficácia do sistema por meio de dois experimentos: um *offline* controlado com o corpus DBLP-v10 e um *online* no formato de Teste A/B com pesquisadores reais. Por fim, o Capítulo 7 apresenta o progresso acadêmico e o cronograma das atividades da pesquisa.

SISTEMAS DE RECOMENDAÇÃO

O excesso de informação, seja ela produzida ou disponibilizada atualmente, pode representar um grande peso para o usuário. Por isso, nesse cenário conturbado, muitas tecnologias foram desenvolvidas para filtrar as informações que o usuário deseja. Este capítulo tem como objetivo apresentar os contornos dos Sistemas de Recomendação, por meio de uma visão geral, introduzindo, ao mesmo tempo, seus principais conceitos, funções, técnicas e possíveis propósitos, como acurácia e diversidade.

2.1 HISTÓRICO

Os Sistemas de Recomendação (SR), ao menos os iniciais, eram sistemas bem rudimentares de filtragem e recuperação de informações, capazes apenas de recomendar alguns resultados com base na pesquisa. O primeiro deles foi um sistema experimental de filtragem de imagens, o Tapestry (GOLDBERG et al., 1992), desenvolvido por pesquisadores do Xerox Palo Alto Research Center. Esse sistema foi desenvolvido para atender a uma simples motivação: lidar com o aumento do número de *e-mails* que o centro de pesquisa recebia (RESNICK; VARIAN, 1997). O Tapestry surgiu para lidar com a filtragem colaborativa (foram pioneiros no uso desse termo), além da filtragem de conteúdo. O sistema colaborativo filtra e arquiva os *e-mails* com base na forma como as pessoas reagem após lê-los.

As recomendações personalizadas, em termos mais simples, são fornecidas como listas ranqueadas de itens. Na tentativa de criar uma lista como essa, os Sistemas de Recomendação (SRs) procuram prever quais produtos ou serviços são mais convenientes, isto é, quais deles melhor condizem com as expectativas do usuário. Como resultado, realiza-se a coleta das preferências do usuário, que podem ser explicitadas, como ao avaliar produtos, ou inferidas, como no sistema, a partir do acesso à página de um produto, considerado um sinal implícito de preferência (RICCI et al., 2011).

Normalmente, as pessoas acabam sempre dependendo do que é recomendado por outros, seja uma recomendação feita por amigos, *reviews* de livros e filmes, ou guias de restaurantes. Desta forma, o SR apoia e intensifica esse processo natural (RESNICK; VARIAN, 1997). Os SRs, portanto, são técnicas e ferramentas de software que oferecem

recursos úteis a diferentes tipos de usuários. Nesses mesmos sistemas, o termo “item” ainda é bastante genérico, denotando apenas o que é recomendado pelo sistema (RICCI et al., 2011).

Os SR estão por toda parte, principalmente na indústria de serviços, no consumo de conteúdo e no comércio eletrônico. Em muitas aplicações modernas, esses sistemas também são encontrados, principalmente ao entregar uma coleção enorme de itens, recomendando opções ao usuário final, ao mesmo tempo em que utilizam uma combinação de abordagens baseadas em conhecimento, conteúdo e filtragem colaborativa (RICCI et al., 2011). Nesse sentido, a Netflix¹, serviço de *streaming* de filmes, mostra predições de classificação para cada vídeo assistido, auxiliando o usuário a decidir se deve assisti-lo ou não. A Amazon², uma loja virtual, oferece, na página de um produto, informações sobre outras compras realizadas por usuários que o adquiriram (SHANI; GUNAWARDANA, 2009).

À medida que as informações disponíveis na Web crescem rapidamente, somadas ao surgimento de muitos tipos de serviços, acabam por sobrecarregar o usuário (leilões, compras e comparações de produtos, entre outros), levando-o a tomar decisões sem critérios, que podem ser pobres ou erradas. As opções disponíveis, em vez de serem uma ajuda, tornam-se, na verdade, um obstáculo para o usuário (RICCI et al., 2011). Novos itens são oferecidos pelos SRs que não foram vistos antes, como páginas Web, produtos, filmes ou livros, tudo isso com base nas preferências do usuário, mantidas em seu perfil. Os SRs, na tentativa de resolver o problema de sobrecarga de informações, filtram os itens que correspondem aos interesses dos usuários. Ao filtrar as informações irrelevantes, esses sistemas acabam ajudando muito quando os usuários pesquisam por informações de interesse (AMINI; IBRAHIM; OTHMAN, 2011).

Alguns critérios, como “interessante, útil e relevante” ou “individualizada”, diferenciam os SRs dos motores de busca e dos sistemas de recuperação de informação. Em um motor de busca, durante a pesquisa, o sistema retorna tudo o que corresponde ao termo pesquisado. Já os motores de busca utilizam técnicas como RR (em inglês, *Relevance Feedback - RF*) para inserir o usuário no processo de pesquisa, garantindo que ele mesmo seja capaz de indicar o que é realmente relevante (BURKE, 2002).

2.2 CONCEITOS

O SR, com base nos dados utilizados, normalmente se refere a três tipos de objetos: itens, usuários e transações (RICCI et al., 2011).

- **Itens:** Eles nada mais são do que os objetos recomendados. São caracterizados pela utilidade, pelos valores ou mesmo pela complexidade. O valor, se positivo, é útil ao usuário. Por outro lado, se for negativo, o item é inapropriado, o que indica que o usuário fez uma escolha incorreta ao selecioná-lo. Os itens, sem dúvida, podem ser representados, principalmente ao se utilizar várias estratégias de representação e de informação.

¹<https://www.netflix.com>

²<http://www.amazon.com/>

- **Usuários:** No SR, os usuários não são homogêneos e, portanto, podem apresentar diversos objetivos e características. Para personalizar as recomendações, os SRs investigam muitas das preferências dos usuários. Elas podem ser organizadas de várias formas, sendo que a seleção de quais informações vão ser modeladas depende da técnica de recomendação.
- **Transações:** As transações são registros de interação entre o Sistema de Recomendação e o usuário. Lembram muitos dados de log, pois armazenam tudo o que é relevante durante a interação humano-computador. Essas mesmas informações são úteis para que o algoritmo que o sistema utiliza gere a recomendação.

2.3 TAREFAS DE UM SISTEMA DE RECOMENDAÇÃO

Uma lista de tarefas para um SR foi sugerida (RICCI et al., 2011), com base nos interesses do criador do Sistema de Recomendação.

- **Aumentar o número de itens vendidos:** Em um SR comercial, esta é provavelmente a função mais importante. Ela precisa ter a capacidade de vender um conjunto de itens adicionais, ao mesmo tempo que compara com aqueles que venderiam sem qualquer tipo de recomendação.
- **Vender mais itens diferentes:** A função que permite ao usuário encontrar itens que seriam difíceis de encontrar sem uma recomendação clara é também muito importante dentro do SR.
- **Aumentar a satisfação do usuário:** Para aumentar a avaliação subjetiva do usuário sobre o sistema, uma forma é combinar recomendações precisas com uma interface bem estruturada. Isso acaba aumentando o fluxo de uso do sistema e as chances de as recomendações serem aceitas.
- **Aumentar a fidelidade do usuário:** É preciso que o usuário mantenha um grau de fidelidade com o site, sendo que este o reconhece como cliente antigo, tratando-o com maior relevância. Esse recurso é muito comum em SR, como se pode perceber, pois calcula recomendações com base no que o usuário adquiriu em contatos anteriores.
- **Melhor entendimento do que o usuário quer:** No SR, muitas coisas podem ser reutilizadas para vários objetivos, como, por exemplo, a descrição das preferências do usuário, coletadas explicitamente ou preditas pelo sistema.

Existem onze tarefas em que um SR auxilia no apoio do usuário com seus objetivos (HERLOCKER et al., 2004):

- **Anotação em Contexto:** Destaca os itens de acordo com as preferências do usuário, dada uma certa lista em um contexto.

- **Encontrar Bons Itens:** Oferece uma lista com um *rank* dos itens sugeridos, antecipando o gosto desses usuários.
- **Encontrar Todos os Bons Itens:** Oferece ao usuário uma lista de itens que atendem às suas necessidades. Em alguns casos, contudo, encontram poucos itens satisfatórios, o que pode não ser suficiente. Na verdade, o sistema precisa carregar uma taxa de “falso negativo” bem reduzida.
- **Recomendar uma Sequência:** O objetivo aqui é recomendar uma sequência de itens relacionados em determinado sentido.
- **Recomendar um Grupo:** Recomendar um conjunto de itens interessantes ao usuário.
- **Apenas Navegar:** Para usuários que navegam sem um rumo definido, o sistema acaba auxiliando, ao mesmo tempo em que navega entre os itens que possam ser interessantes naquela sessão específica.
- **Encontrar Sistema de Recomendação Confiável:** O Sistema de Recomendação deve possibilitar que o usuário teste algumas funções, já que ele pode ter desconfiança, de início, desse sistema.
- **Melhorar o Perfil:** O sistema deve ser configurado com base nas preferências do usuário sobre o que gosta ou não gosta. Essas informações aprimoram a qualidade das recomendações.
- **Expressar-se:** O sistema precisa oferecer uma área reservada para comentários dos usuários, já que alguns deles não se importam com as recomendações, mas apenas se interessam em contribuir com as qualificações.
- **Ajudar os Outros:** Alguns usuários, ao acreditarem que a comunidade se beneficia de sua avaliação, gostam de compartilhar informações.
- **Influenciar os Outros:** Alguns usuários maliciosos podem tentar induzir a escolha dos outros ou simplesmente utilizar o sistema para promover ou penalizar um item.

2.4 TÉCNICAS DE RECOMENDAÇÃO

São utilizadas técnicas para a elaboração das recomendações, com base na predição das informações dos itens e dos usuários. Algumas técnicas foram criadas para atuar como suporte a um SR, como as colaborativas, baseadas em conteúdo, baseadas em conhecimento e demográficas. As técnicas de recomendação se ramificam, dependendo de suas fontes de conhecimento. Em certos sistemas, elas se baseiam nas preferências de outros usuários (BURKE, 2007).

O conhecimento que o usuário possui no domínio influencia a utilidade do item, como no caso de usuários iniciantes e experientes de uma câmera digital, ou pode depender do momento em que a recomendação foi feita. Além disso, o usuário pode pensar de

forma mais conveniente ao demonstrar maior interesse por itens mais próximos do seu local atual, como um restaurante. Desse modo, a recomendação precisa ser adaptada, considerando esses detalhes específicos e adicionais (RICCI et al., 2011).

Existem quatro diferentes classes de técnicas de recomendação baseadas em fontes de conhecimento (BURKE, 2007), como ilustrado na Figura 2.1:




Figura 2.1 Técnicas de recomendação e suas fontes de conhecimento (BURKE, 2007).

- **Filtragem Colaborativa:** A partir de itens de outros usuários, com gostos similares, o sistema gera recomendações para certo usuário.
- **Baseada em Conteúdo:** O sistema produz duas fontes de recomendação: as características associadas ao item e as classificações que os usuários atribuíram a ele.
- **Demográfica:** Com base no perfil demográfico do usuário, o sistema fornece recomendações.
- **Baseada em Conhecimento:** Com base em inferências sobre os gostos e necessidades do usuário, o sistema sugere determinados itens.

Dentre as técnicas de recomendação apresentadas, duas são as mais utilizadas na literatura: a Filtragem Colaborativa e a Baseada em Conteúdo. Em seguida, essas duas técnicas são apresentadas em detalhes.

2.4.1 Filtragem Colaborativa

Na Filtragem Colaborativa, o sistema recomenda itens ao usuário ativo com base nos gostos de outros usuários no passado. A semelhança das preferências entre os usuários é

calculada com base na equivalência entre os respectivos históricos de classificação. Essa técnica é considerada uma das mais populares nos Sistemas de Recomendação e a mais amplamente implementada (RICCI et al., 2011).

O ponto principal é que a classificação de um usuário u para um novo item i provavelmente será semelhante à de outro usuário v se u e v tiverem classificado, de forma similar, outros itens. De forma idêntica, é possível que u classifique os itens i e j de forma equivalente se outros usuários tiverem feito classificações semelhantes desses itens (RICCI et al., 2011).




Figura 2.2 Filtragem Colaborativa baseada em usuários.

Os métodos de filtragem colaborativa podem ser agrupados em duas classes gerais, baseadas em *vizinhança* e em *modelo* (BURKE, 2002) e (BURKE, 2007). Com base em *vizinhança*, as classificações usuário-item armazenadas no sistema são utilizadas diretamente para prever as classificações de novos itens. O *user-based* (baseado em usuários) ou *item-based* (baseado em itens) é o mais conhecido (RICCI et al., 2011).

Os sistemas, ao menos os baseados em usuários, avaliam a preferência de um usuário u por um item i com base nas classificações de outros usuários sobre esse item. Esses usuários são chamados de *vizinhos* porque compartilham os mesmos padrões de classificação. Os *vizinhos* do usuário u são tipicamente os usuários v , cujas classificações, para os itens classificados por u e v , isto é, I_{uv} , são mais correlacionadas com as de u . A Figura 2.2 ilustra a abordagem baseada em usuários em um cenário de filmes. A Usuária 01 indicou que gosta dos 4 filmes, *Jurassic Park*, *Moulin Rouge*, *Os Croods* e *Homem Aranha*, a Usuária 02 mostrou que gosta apenas do filme *Moulin Rouge* e o Usuário 03 mostrou preferência pelos filmes *Moulin Rouge* e *Os Croods*. O sistema baseado em usuários entende que a

Usuária 01 é a que possui preferências mais similares às do Usuário 03, logo indicará ao Usuário 03 os filmes *Jurassic Park* e *Homem Aranha*, pois a Usuária 01 também gostou desses filmes. Em outras palavras, a Usuária 01 é *vizinha* do Usuário 03.




Figura 2.3 Filtragem Colaborativa baseada em itens.

A abordagem baseada em itens, por outro lado, prediz a classificação de um usuário u para um item i com base nas classificações de u para itens similares a i ais. Nessa linha de raciocínio, dois itens são equivalentes se, por acaso, muitos usuários do sistema os classificam como equivalentes (RICCI et al., 2011). Um exemplo da abordagem baseada em itens é ilustrado na Figura 2.3 em um cenário de filmes. A Usuária 01 gostou dos filmes *Jurassic Park*, *Os Croods* e *Homem Aranha*, a Usuária 02 gostou de *Jurassic Park* e *Os Croods* e o Usuário 03 gostou do filme *Os Croods*. Assumindo que o sistema deve indicar algum filme ao Usuário 03, essa abordagem buscará filmes com avaliações semelhantes ao filme *Os Croods*. Então, esse sistema indicará *Jurassic Park* ao Usuário 03, pois esse filme recebeu duas avaliações, assim como o filme *Os Croods*; ou seja, *Os Croods* e *Jurassic Park* são considerados vizinhos.

As abordagens baseadas em modelo usam essas classificações para aprender um modelo preditivo, ao contrário dos sistemas baseados em vizinhança, que utilizam as classificações armazenadas diretamente na predição. A proposta principal é reconfigurar as relações usuário-item com fatores, representando assim características ocultas dos usuários e itens no sistema, como a classe de preferência do usuário e a classe dos itens em categoria. Este modelo é treinado utilizando aqueles dados à disposição e, depois, é utilizado para prever classificações de usuários para itens inéditos (RICCI et al., 2011).

2.4.2 Filtragem Baseada em Conteúdo

Sistemas que usam a estrutura de recomendação colaborativa identificam usuários com preferências semelhantes e sugerem itens dos quais um determinado usuário gostou, ao passo que os sistemas de recomendação baseados em conteúdo tentam recomendar itens semelhantes aos que um mesmo usuário gostou no passado (LOPS; GEMMIS; SEMERARO, 2011).

Sistemas que implementam uma estrutura de recomendação baseada em conteúdo analisam uma série de documentos e/ou descrições de itens previamente classificados por um usuário, construindo um modelo ou perfil de interesses, fundamentado nas características dos objetos classificados (MLADENIC, 1999). O perfil é uma representação estruturada das preferências do usuário, adaptada para sugerir itens inéditos e interessantes. O processo de recomendar itens nada mais é do que a combinação das similaridades entre os atributos do perfil do usuário e os atributos de um objeto de conteúdo. Como consequência disso, ocorre um julgamento de relevância que representa o nível de interesse do usuário em relação a esse objeto. Se um perfil descreve, com precisão, as escolhas do usuário, isso é uma grande vantagem para que o acesso à informação seja eficaz. Por exemplo, poderia ser usado para filtrar os resultados de pesquisa, na tentativa de decidir se um usuário tem interesse ou não em uma página Web particular, e, em caso negativo, impedir que seja mostrada (LOPS; GEMMIS; SEMERARO, 2011).

2.4.3 Arquitetura de Sistemas de Recomendação Baseados em Conteúdo

Em sistemas baseados em conteúdo, é preciso usar técnicas adequadas para representar os itens, produzir o perfil do usuário e adotar estratégias para comparar o perfil do usuário com a representação dos itens (LOPS; GEMMIS; SEMERARO, 2011). A estrutura da recomendação é feita através de três passos, cada um deles manipulado por um componente separado:

- **Analizador de Conteúdo:** É preciso algum tipo de pré-processamento para extrair informação relevante e estruturada, principalmente quando a informação não tem estrutura, como em um texto. A responsabilidade central do componente é representar o conteúdo dos itens (por exemplo, descrição de produtos, notícias, páginas Web, documentos, etc.), todos eles originados de informações adequadas para o próximo passo de processamento.
- **Aprendiz de Perfil:** Para construir o perfil do usuário, este módulo organiza as informações representativas dos seus gostos e tenta generalizar estes dados. Normalmente, a estratégia de generalização é produzida por meio de técnicas de *aprendizado de máquina*, que têm a capacidade de inferir um modelo de interesses de usuário, com base em itens gostados ou não gostados no passado.
- **Componente de Filtragem:** Este módulo investiga o perfil do usuário para sugerir itens relevantes, combinando, para tanto, a representação do perfil com os itens a serem recomendados. A consequência é um julgamento binário ou contínuo de relevância, por meio de alguma métrica de similaridade (HERLOCKER et al.,

2004). Nesse último caso, resulta em uma lista com um *rank* de itens relevantes potenciais.




Figura 2.4 Arquitetura de alto nível de um Sistema de Recomendação Baseado em Conteúdo (LOPS; GEMMIS; SEMERARO, 2011).

Na Figura 2.4 é possível observar a arquitetura de alto nível de um Sistema de Recomendação baseado em conteúdo. O passo 1 consiste na descrição dos itens trabalhados por aquele sistema, seguido do passo 2, em que esses itens são armazenados de forma estruturada após o tratamento pelo Analisador de Conteúdo. Em seguida, o passo 3 consiste na utilização dos usuários U_k como exemplos de treino para o Aprendiz de Perfil. Os perfis gerados são armazenados no passo 4 para serem posteriormente utilizados pelo Componente de Filtragem. Após a realização da filtragem, é gerada uma lista de recomendações para o usuário ativo U_i , e o *feedback* desse usuário é coletado e armazenado no passo 5. Esse *feedback* é então enviado ao componente de aprendizagem para melhorar o funcionamento do sistema e iniciar o ciclo de aprendizagem.

2.4.4 Comparação das Técnicas de Recomendação

Existem sempre pontos fortes e fracos em todas as técnicas de recomendação. Alguns desses pontos são (BURKE, 2002):

- **Usuário Novo:** Através unicamente de um acúmulo de classificações, as recomendações partem da comparação entre o usuário-alvo e outros usuários, o que faz com que um usuário com poucas classificações não consiga categorizar bem os itens.

- **Item Novo:** De igual maneira, um novo item, que não recebeu muitas classificações, também não pode ser facilmente recomendado: essa é a problemática do “item novo”. Ele também é conhecido como a problemática do “*early rater*”, já que a primeira pessoa responsável por classificar um item recebe poucos benefícios para fazer isso. Isso acaba fazendo com que os Sistemas de Recomendação forneçam outros incentivos para motivar usuários a produzir classificações.

Nos locais onde poucos usuários classificam os mesmos itens, os Sistemas de Recomendação colaborativos precisam das recomendações entre usuários, já que podem ter dificuldades quando o espaço de classificação é esparsa.

Em situações em que a densidade de interesse do usuário é relativamente alta em um universo de itens pequeno e estático, esses problemas sugerem que técnicas colaborativas puras são mais adequadas. Se houver alguma mudança abrupta, as velhas classificações serão de pouco valor para os usuários mais novos, pois não terão condições de compará-las às dos usuários existentes. Segundo (BURKE, 2002), se a quantidade de itens é enorme e o gosto do usuário se espalha pouco, a probabilidade de sobreposição com outros usuários será bem reduzida.

Em um nicho com muitos vizinhos de gostos parecidos, os Sistemas de Recomendação colaborativos funcionam melhor para um usuário. A técnica não opera muito bem para o chamado “*gray sheep*” (CLAYPOOL et al., 1999); despenca no espaço entre as panelinhas de usuários existentes. Isso também se aplica aos sistemas demográficos que buscam categorizar usuários com base em características pessoais. Por outro lado, o “usuário novo” não é um problema para os sistemas de Recomendação demográficos, e isso porque eles não precisam de uma lista de classificações desses usuários. Segundo (BURKE, 2002), em vez disso, eles têm o problema de reunir as informações demográficas relevantes.

2.4.5 Cálculo de similaridade

Independentemente da técnica de recomendação utilizada, em determinado ponto, o Sistema de Recomendação realizará um cálculo de similaridade, seja entre itens, seja entre usuários. Na literatura, há diversos modelos propostos para realizar esse cálculo, e alguns serão apresentados aqui. As métricas mais populares para o cálculo da similaridade entre usuários são as equações de correlação de Pearson e de similaridade do cosseno (ADOMAVICIUS; TUZHILIN; ALEXANDER, 2005). Por outro lado, se o interesse for calcular a similaridade entre os itens, métricas que comparem as características textuais são mais comuns na literatura e geralmente utilizam o método *Term Frequency/Inverse Document Frequency*(TF-IDF) (SALTON, 1988).

- **Correlação de Pearson:** Na Equação 2.1, $sim(u, v)$ denota a similaridade entre os usuários u e v . O termo $r_{u,i}$ é a avaliação atribuída ao item i pelo usuário u e $\bar{r}_u$ é a avaliação média dada pelo usuário u sobre todos os n itens avaliados no espaço desse usuário. Além disso, a predição para um item é obtida pela combinação ponderada das avaliações dos *vizinhos* selecionados, calculada como o desvio ponderado em relação à média dos *vizinhos* (SARWAR et al., 2001).

$$\text{simPearson}(u, v) = \frac{\sum_{i=1}^n (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i=1}^n (r_{u,i} - \bar{r}_u)^2} \sqrt{\sum_{i=1}^n (r_{v,i} - \bar{r}_v)^2}} \quad (2.1)$$

- **Similaridade de Cossenos:** A similaridade de cossenos é um modelo de espaço vetorial baseado na álgebra linear. Esta métrica de similaridade calcula o ângulo entre dois vetores i – *dimensionais* (u e v) e é amplamente utilizada nos campos de recuperação de informação e mineração de textos a fim de comparar dois documentos; neste caso, os documentos são representados como vetores de termos (ISINKAYE; FOLAJIMI; OJOKOH, 2015). Sendo assim, essa métrica é amplamente utilizada tanto nos sistemas *user-based* quanto nos *item-based*, visto que a diferença entre eles se dá apenas no domínio a ser utilizado na representação vetorial. A similaridade entre dois usuários u e v pode ser definida pela Equação 2.2. O termo I_{uv} representa os itens em comum entre os usuários u e v .

$$\text{simCosine}(u, v) = \frac{\sum_{i \in I_{uv}} r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i \in I_{uv}} r_{u,i}^2} \sqrt{\sum_{i \in I_{uv}} r_{v,i}^2}} \quad (2.2)$$

- **Term Frequency/Inverse Document Frequency (TF-IDF):** Assumindo que existem N documentos que podem ser recomendados a um usuário, e que uma palavra-chave k_i aparece em n_i documentos, e que f_{ij} é o número de vezes que k_i aparece no documento d_j . Então, o *Term Frequency*, TF_{ij} , nada mais é do que a frequência com que o termo k_z apareceu nos N documentos (ADOMAVICIUS; TUZHILIN; ALEXANDER, 2005). A Equação 2.3 ilustra esse processo.

$$TF_{ij} = \frac{f_{ij}}{\max_z f_{zj}} \quad (2.3)$$

No entanto, saber apenas a frequência de palavras em um documento não basta para determinar sua relevância nesse documento. Para tal, utiliza-se o método *Inverse Document Frequency* IDF_i combinado com o TF_{ij} . O IDF_i é definido na Equação 2.4.

$$IDF_i = \log \frac{N}{n_i} \quad (2.4)$$

Portanto, no TF-IDF, o peso do termo k_i no documento d_j é definido pela Equação 2.5.

$$p_{ij} = TF_{ij} \times IDF_i \quad (2.5)$$

2.5 OBJETIVOS DE SISTEMAS DE RECOMENDAÇÃO

Um Sistema de Recomendação é normalmente avaliado em termos de corretude. É normal avaliarmos o quão precisas foram as recomendações do sistema. Na literatura, existem métricas bem consolidadas que avaliam a precisão das recomendações, dentre elas, a Precisão e o *Root Mean Square Error (RMSE)*. No entanto, vê-se também a discussão de outros parâmetros, além da acurácia, na avaliação de Sistemas de Recomendação, dentre eles o grau de diversidade entre os itens recomendados.

2.5.1 Acurácia

Em um Sistema de Recomendação, é fundamental avaliar se os itens retornados ao usuário como recomendações são, de fato, relevantes. Nesse contexto, uma das métricas mais utilizadas na literatura é a precisão (*precision*), empregada para medir a proporção de itens recomendados que são efetivamente relevantes para o usuário (PARRA; SAHEBI, 2013).

Precisão é a porcentagem de itens recomendados relevantes para o usuário (MAN-NING; RAGHAVAN; SCHÜTZE, 2008), definida pela Equação 2.6.

$$precisao = \frac{\text{itens relevantes recomendados}}{\text{total de itens recomendados}} \quad (2.6)$$

Outra abordagem utilizada para medir a acurácia é a métrica *Root Mean Square Error (RMSE)* que visa calcular a magnitude do erro nas recomendações realizadas. Como essa métrica utiliza um termo ao quadrado no somatório, o RMSE penaliza de forma desproporcional grandes erros no conjunto de dados. A Equação 2.7 mostra como o cálculo é realizado.

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (r_i - p_i)^2}{n}}, \quad (2.7)$$

Onde n é o número total de avaliações de todos os usuários, p_i é a avaliação prevista do usuário i no item p , e r_i é a avaliação real desse usuário sobre o item.

2.6 SUMÁRIO

Neste capítulo, foi possível obter uma visão mais ampla dos sistemas de recomendação. Primeiramente, um breve histórico. Logo depois, foram apresentados alguns conceitos sobre os dados manuseados em um sistema. Então, foi sugerida uma lista de tarefas desempenhadas pelos Sistemas de Recomendação. Discutiram-se também as técnicas de recomendação mais fundamentais e algumas métricas de similaridade. Por fim, foram apresentados alguns objetivos em Sistemas de Recomendação, como manter a acurácia das recomendações e diversificá-las. No Capítulo 4, serão apresentados trabalhos com focos semelhantes aos desta pesquisa, a fim de fornecer uma base argumentativa e um ponto de partida para o desenvolvimento das metas de solução estabelecidas.

SISTEMAS DE RECOMENDAÇÃO EDUCACIONAIS

Os Sistemas de Recomendação (SRs) têm se destacado em diversos contextos, incluindo o campo educacional, onde desempenham um papel essencial na personalização do aprendizado. Ao adaptar conteúdos e recursos educativos às necessidades e preferências individuais dos alunos, esses sistemas buscam aumentar a eficácia do aprendizado e o engajamento dos estudantes. A personalização promovida pelos SRs permite que cada aluno tenha acesso a materiais que melhor se adequem ao seu nível de conhecimento e ao seu estilo de aprendizado, seja por meio de livros, artigos, vídeos ou outros recursos de aprendizagem (SILVA et al., 2023).

Em ambientes educacionais, os SRs oferecem uma forma dinâmica e interativa de apoiar o processo educativo, ajustando continuamente as recomendações com base no desempenho do aluno e nas suas interações anteriores com o conteúdo (COSTA; AGUIAR; MAGALHÃES, 2013). Essa adaptabilidade é fundamental para criar experiências de aprendizado mais significativas e motivadoras, que não apenas facilitam o acesso a informações relevantes, mas também promovem uma aprendizagem ativa e personalizada (MARUYAMA et al., 2023). Estudos recentes demonstram o potencial dos SRs para integrar diversos métodos de ensino e tecnologias emergentes, proporcionando alternativas eficazes para enfrentar os desafios educacionais contemporâneos (CAZELLA et al., 2009).

No entanto, apesar de seu potencial, os SRs em contextos educacionais enfrentam desafios significativos, especialmente quanto à disponibilidade e à qualidade dos conjuntos de dados educacionais. Muitos desses conjuntos de dados carecem de variáveis de contexto importantes ou apresentam lacunas na captura de preferências multicritérios dos usuários, como avaliações detalhadas de conteúdos e facilidade de uso (ZHENG, 2023). Essas deficiências limitam a capacidade dos algoritmos de recomendação de fornecer sugestões precisas e adaptadas, sublinhando a necessidade de desenvolver novas abordagens para a coleta e utilização de dados educacionais mais ricos e diversificados.

3.1 INTRODUÇÃO

Acerca das recomendações com foco em aprendizado, há uma deficiência nos conjuntos de dados educacionais, como a ausência de variáveis de contexto ou lacunas no preenchimento de preferências multicritérios dos usuários, tais como avaliações, facilidade de uso

e qualidade dos conteúdos (ZHENG, 2023). Ainda assim, há alternativas para os mais diversos problemas enfrentados atualmente. Maruyama *et al.* (2023) fornece um exemplo prático de integração entre o mundo real e o virtual, com foco no ambiente universitário e na adoção de alternativas que abrangem diversos métodos de aprendizado. Além disso, é importante considerar que a diversidade de dados e de métodos utilizados pode impactar diretamente a eficácia dos SRs educacionais. A personalização das recomendações pode ser afetada pela qualidade dos dados disponíveis e pela capacidade dos algoritmos de recomendação de interpretar e utilizar essas informações de forma eficaz.

3.2 OBJETOS DE APRENDIZAGEM RECOMENDADOS

Na área de recomendações educacionais, as contribuições mais produtivas dos sistemas são fornecidas por meio de objetos de aprendizagem. Estes podem ser apresentados de diversas formas, como mídias audiovisuais, livros ou textos. Silva *et al.* (2023) exemplificam diversos métodos para a geração dessas recomendações. A abordagem híbrida, que combina diferentes métodos de recomendação, pode ser mais eficaz na personalização de objetos de aprendizagem para atender às necessidades dos alunos, bem como no desenvolvimento de sistemas adaptativos, que podem melhorar a experiência por meio do uso de objetos de aprendizagem auxiliares.

A revisão também ajuda na identificação de tendências atuais na pesquisa sobre SRs educacionais, orientando futuros esforços de pesquisa e desenvolvimento, como a integração de múltiplas fontes de dados, com o objetivo de melhorar a personalização das recomendações e a criação de modelos que considerem fatores afetivos e sociais no processo. Por exemplo, integrar dados sobre o estado emocional do aluno ou sobre seu histórico social e cultural pode enriquecer significativamente o processo de personalização, resultando em recomendações mais relevantes e eficazes.

Costa, Aguiar e Magalhães (2013) apresentam elementos que melhoram a experiência dos SRs educacionais, em conjunto com a utilização de sistemas de recomendação personalizada, como aprimoramento dos recursos de ensino e de suas descobertas, apoio a necessidades de aprendizagem diversas, entrega de conteúdo personalizado e aumento do engajamento dos estudantes. Tais sistemas também permitem que os educadores acompanhem o progresso e adaptem as recomendações com base em *feedback* contínuo, o que aumenta a eficácia do ensino e a satisfação do aluno.

Cazella *et al.* (2009) elaboraram um SR de objetos de aprendizagem com base em filtragem colaborativa. Esta, quando aplicada no sistema, auxilia no processo de análise das preferências e das avaliações dos usuários. O trabalho contribui com alternativas para a integração de competências no processo de recomendação, possibilitando uma melhor personalização do aprendizado de cada aluno, além de utilizar práticas do estado da arte. Estes objetivos visam melhorar a experiência de aprendizado dos alunos, tornando-a mais adaptada às suas necessidades e contextos específicos. Além disso, o uso de filtragem colaborativa permite capturar padrões emergentes de interesse entre grupos de usuários, facilitando a descoberta de novos conteúdos relevantes para comunidades específicas de aprendizagem.

3.3 ARQUITETURA DAS APLICAÇÕES

Com o objetivo de acelerar o processo de desenvolvimento dos SRs, foram desenvolvidos diversos *frameworks* com modelos de arquitetura predefinidos, exemplificados por Carvalho *et al.* (2018) e García e Bellogín (2018), que permitem a elaboração de modelos flexíveis e escaláveis. Noble e Smith (2015) e Declerq e van Poppel (2023) aprofundam a validade e a confiabilidade dos dados que alimentam SRs, e Brouwer e Hollenbach (2022) contribuem com parâmetros e implementações para a otimização de motores de busca. Estes *frameworks* são essenciais para permitir que desenvolvedores implementem rapidamente SRs, garantindo, ao mesmo tempo, que sejam robustos e capazes de lidar com grandes volumes de dados e com diferentes tipos de usuários. Além disso, a arquitetura flexível permite a incorporação de novos algoritmos e técnicas à medida que a tecnologia evolui e novas necessidades dos usuários são identificadas.

Os SRs educacionais frequentemente enfrentam desafios relacionados à arquitetura de suas aplicações, incluindo a necessidade de escalabilidade, flexibilidade e integração com múltiplas fontes de dados. Por exemplo, a Revista DNC (2024) discute a implementação de um SR para cursos educacionais, destacando o uso de arquiteturas modulares que permitem a adaptação e a extensão com facilidade. A arquitetura adotada inclui componentes de pré-processamento de dados, modelos híbridos de recomendação e um mecanismo de *feedback* dos usuários para aprimorar continuamente as recomendações. Além disso, são exploradas soluções para a integração de dados de diferentes plataformas e para a personalização das recomendações com base em múltiplos critérios, como o histórico de aprendizagem e as preferências declaradas pelos usuários.




Figura 3.1 Modelo arquitetural para SRs educacionais.

Conforme discutido por Costa, Aguiar e Magalhães (2013), uma arquitetura eficiente deve combinar técnicas de recomendação para atender melhor às necessidades específicas dos usuários. A Figura 3.1 apresenta alguns dos componentes arquiteturais explorados,

como módulos de personalização e mecanismos de *feedback*, que permitem ajustes contínuos nas recomendações fornecidas. A flexibilidade e a escalabilidade da arquitetura são cruciais para lidar com a diversidade de dados e de preferências dos usuários em ambientes educacionais.

O artigo de Yazdi, Mahdavi e Yazdi (2024) apresenta um SR educacional dinâmico baseado em uma rede neural Long Short-Term Memory (LSTM) aprimorada. Essa arquitetura é particularmente adequada para aplicações educacionais devido à sua capacidade de modelar sequências temporais e capturar dependências de longo prazo nos dados dos usuários. A abordagem proposta utiliza uma combinação de técnicas de aprendizado supervisionado e não supervisionado para ajustar as recomendações em tempo real, adaptando-se continuamente ao comportamento do usuário e às mudanças nas preferências de aprendizagem. Essa flexibilidade arquitetural é essencial para construir SRs robustos e escaláveis, que podem ser facilmente adaptados a diferentes contextos educacionais.

3.4 SISTEMAS DE RECOMENDAÇÃO PARA ARTIGOS CIENTÍFICOS

Embora existam alguns trabalhos com foco em recomendações para manuscritos científicos, estes não levam em conta o perfil do pesquisador. Este fator tem potencial para reduzir o esforço na busca por trabalhos relacionados, por meio da coleta de dados para a elaboração do perfil do usuário e do fornecimento passivo de recomendações. A consideração do perfil do pesquisador, incluindo suas publicações anteriores, interesses de pesquisa e rede de colaboradores, pode significativamente aprimorar a relevância das recomendações fornecidas, promovendo descobertas mais alinhadas aos interesses e às necessidades de pesquisa de cada usuário.

Embora o artigo de Costa, Aguiar e Magalhães (2013) tenha foco em recursos educacionais mais amplos, ele fornece *insights* relevantes para a recomendação de artigos científicos. Eles destacam a importância de adotar uma abordagem híbrida que combine técnicas baseadas em conteúdo e filtragem colaborativa para melhorar a precisão e a relevância das recomendações. Esse tipo de abordagem é particularmente útil para sistemas que recomendam artigos científicos, pois pode aproveitar tanto as características textuais dos artigos quanto os padrões de citação e de uso por parte dos pesquisadores.

Kreutz e Schenkel (2022) apresentam uma revisão da literatura que sinaliza alguns destes trabalhos, percorrendo sobre os métodos aplicados, os *datasets* utilizados e as variáveis analisadas nas etapas de avaliação. A revisão também destaca a importância de adotar abordagens que integrem diferentes tipos de dados, como metadados de publicações, referências cruzadas e até mesmo métricas de impacto social, para construir SRs mais completos e eficazes no contexto científico.

Embora o artigo de Yazdi, Mahdavi e Yazdi (2024) se concentre principalmente em SR educacional, os conceitos de modelagem de sequência com LSTM também podem ser aplicados a sistemas de recomendação de artigos científicos. A habilidade das LSTMs em capturar padrões temporais complexos torna-as úteis para rastrear as tendências de leitura e citação de pesquisadores ao longo do tempo, permitindo um modelo de recomendação mais sofisticado que leva em conta o histórico de leitura e os interesses

evolutivos dos usuários.

3.5 SUMÁRIO

Neste capítulo, foram explorados os conceitos de SR educacional e seu papel na personalização do aprendizado. Inicialmente, destacou-se a capacidade desses sistemas de adaptar conteúdos às necessidades individuais dos alunos, promovendo maior engajamento e eficácia educacional. Foram abordados também os desafios enfrentados na elaboração e na execução deste tipo de sistema, como a escassez de dados educacionais ricos e as lacunas na captura de preferências multicritérios. A seção sobre objetos de aprendizagem recomendados discutiu o uso de mídias audiovisuais, textos e livros, enfatizando abordagens híbridas e sistemas adaptativos para aprimorar a experiência do usuário. Em seguida, a arquitetura das aplicações foi apresentada, com foco em *frameworks* modulares que facilitam o desenvolvimento e integração de novas técnicas. Por fim, o capítulo aborda os SRs para artigos científicos, destacando a importância de considerar o perfil do pesquisador para gerar recomendações mais relevantes. Técnicas híbridas que combinam filtragem colaborativa e análise textual são sugeridas como estratégias eficazes para aprimorar esses sistemas.

SISTEMAS DE RECOMENDAÇÃO DE TEXTOS CIENTÍFICOS

Como mencionado anteriormente, há diversas alternativas focadas em Sistemas de Recomendação (SRs) na área de pesquisa. O foco destes estudos inclui a criação de *frameworks* para a redução do tempo de criação de um SR, a combinação de *Citation Network Information* com similaridade textual para a geração de recomendações, soluções para ambientes de aprendizado acadêmico, entre outros.

4.1 SISTEMAS DE RECOMENDAÇÃO BASEADOS EM SIMILARIDADE TEXTUAL DESESTRUTURADA

Uma das estratégias mais populares para recomendações, a similaridade textual é abordada em trabalhos das mais diversas áreas e com diferentes objetivos. Sterling e Montemore (2022) atuaram na construção de uma *citation network* composta pelos artigos do *dataset*, e na utilização de similaridade textual para identificar trabalhos relacionados. Este processo é realizado utilizando uma mescla entre aprendizado de máquina e mineração de dados, similar à abordagem utilizada em Recademy, tendo o mesmo objetivo principal enquanto adiciona elementos presentes no perfil do pesquisador na comparação de similaridade. A proposta dos autores resultou em uma melhoria significativa na busca por trabalhos relacionados, em comparação com o método tradicional, que utiliza palavras-chave em motores de busca.

Zhao *et al.* (2023) produzem uma revisão sobre o uso de *embeddings* em SRs. Esta técnica é utilizada em Recademy, e é considerada uma grande promessa que surgiu nos últimos anos, tendo melhor desempenho se comparada a abordagens tradicionais. Porém, esta estratégia mais recente ainda carece de avanços em escalabilidade e compreensibilidade, e esta pesquisa abre caminho para futuros trabalhos focados na melhoria destes aspectos.

Um esquema personalizado para recomendações de recursos de aprendizagem *online* foi desenvolvido por Wei *et al.* (2021), baseado em Inteligência Artificiais (IAs) e na teoria da psicologia educacional para aprimorar o aprendizado dos estudantes. O esquema

proposto pode fornecer recomendações precisas, reduzindo o risco de exploração na experiência dos estudantes e facilitando o desenvolvimento de suas capacidades potenciais ao oferecer recursos de aprendizagem adequados. O SR utiliza estratégias semelhantes às do algoritmo de recomendação do Recademy, em especial no que diz respeito à elaboração de um coeficiente que combina elementos dos usuários e dos itens, o qual é utilizado como métrica de comparação de similaridade.

Ricci *et al.* (2022) abordam os problemas enfrentados pelos SRs, como a diversidade de preferências dos usuários e a necessidade de personalização das recomendações. Para solucionar tais desafios, propõe-se o uso de técnicas avançadas, como a análise de *feedback* implícito e a identificação de mudanças contextuais relevantes. As contribuições do artigo incluem a metrificação da importância da personalização e da colaboração na melhoria dos sistemas, juntamente com a exploração de abordagens inovadoras para recomendações contextuais, destacando a interseção com SRs baseados em similaridade textual desestruturada. Estas métricas desenvolvidas auxiliarão na etapa de avaliação do trabalho atual, tanto em relação às recomendações fornecidas quanto à usabilidade da aplicação.

O conceito de filtragem colaborativa é amplamente utilizado na geração de recomendações. Usufruindo deste, Chen *et al.* (2020) desenvolveram um algoritmo baseado na correlação do usuário e *clustering* evolutivo para lidar com problemas de dados esparsos e baixa precisão de recomendação. A solução proposta envolve pré-processamento da matriz de pontuações para obter dados mais densos, aplicação do conceito de correlação do usuário para selecionar nós vizinhos mais próximos na previsão de avaliações e implementação de *clustering* evolutivo dinâmico, sendo estas propostas similares às utilizadas em Recademy para comparar os perfis de pesquisadores aos trabalhos inicialmente selecionados. O artigo também contribui para melhorias na precisão das recomendações, demonstradas por experimentos comparativos com outros algoritmos em diferentes conjuntos de dados, como o do sistema Movielens.

Alhijawi (2020) apresenta um sistema de recomendação colaborativa que utiliza algoritmos genéticos para melhorar a qualidade das recomendações. Ao combinar essas técnicas, o sistema busca encontrar valores de similaridade ótimos entre usuários, abordando problemas de escassez e *cold start*. A contribuição do estudo reside na aplicação eficaz do algoritmo genético para aprender a similaridade entre usuários, minimizando os desafios comuns em sistemas de recomendação colaborativa. A Tabela 4.1 sintetiza os sistemas discutidos nesta seção e sua relação com o Recademy.

Tabela 4.1 Comparativo de Sistemas de Recomendação por Similaridade Textual.

Autor (Ano)	Método / Técnica	Objetivo Principal	Relação com Recademy
Sterling e Montemore (2022)	Redes de citações e similaridade textual.	Identificar trabalhos relacionados de forma eficiente, superando buscas por palavras-chave.	Combina similaridade textual para produzir recomendações mais relevantes e centradas no perfil.
Zhao <i>et al.</i> (2023)	Revisão sobre uso de <i>Word Embeddings</i> .	Demonstrar o desempenho superior das <i>embeddings</i> frente a abordagens tradicionais.	Corroborar e justificar a escolha técnica do uso de <i>Word Embeddings</i> no motor do sistema.
Wei <i>et al.</i> (2021)	Inteligência Artificial e psicologia educacional.	Recomendação personalizada combinando elementos de usuários e itens.	Inspira a formulação do coeficiente de recomendação que une métricas de usuário e item.
Ricci <i>et al.</i> (2022)	Análise de <i>feedback</i> implícito e contexto.	Metrificar a personalização para atender à diversidade de preferências dos usuários.	Fornece diretrizes de métricas de avaliação de usabilidade e relevância das recomendações.
Chen <i>et al.</i> (2020)	Filtragem colaborativa e <i>clustering</i> evolutivo.	Lidar com a dispersão de dados (<i>data sparsity</i>) e aumentar a precisão.	Sustenta propostas de agrupamento usadas para comparar perfis de pesquisadores e trabalhos.
Alhijawi (2020)	Algoritmos genéticos e filtragem colaborativa.	Encontrar valores ótimos de similaridade para mitigar o problema de <i>cold start</i> .	Fornece embasamento teórico para lidar com a escassez de dados observada nos testes do sistema.

4.2 SISTEMAS DE RECOMENDAÇÃO DE MANUSCRITOS CIENTÍFICOS

Dando continuidade à análise das estratégias de recomendação, a transição da similaridade textual desestruturada para o domínio específico dos manuscritos científicos permite observar como os conceitos de Processamento de Linguagem Natural (NLP) e embeddings são aplicados na prática acadêmica. Enquanto as abordagens discutidas na seção anterior fornecem o arcabouço técnico para a comparação semântica e recuperação de documentos, a seção a seguir foca em sistemas projetados para resolver o desafio da descoberta de literatura em um cenário de crescente abundância de recursos digitais. Essa contextualização é fundamental para identificar como ferramentas especializadas buscam preencher a lacuna de integração ao perfil individual do pesquisador, aspecto que, conforme observado, ainda carece de soluções robustas no estado da arte.

Maruyama *et al.* (2023) apontam que encontrar informações de qualidade é um desafio, devido ao drástico aumento de recursos disponíveis na rede. Para sanar este problema, é proposto o desenvolvimento de um sistema híbrido de recomendações atrelado a uma ar-

quitetura de *software* (SmartC) composta por 3 camadas, sendo elas acesso (diretamente disponibilizada aos usuários, apresentando recomendações, redirecionamentos para outros portais da universidade e informações de seus interesses em diversos dispositivos), gerenciamento de recomendações (limitada aos desenvolvedores, responsável por coleta/processamento de dados e envio de informações para banco de dados) e persistência (engloba o banco de dados).

Wang *et al.* (2018) abordam a crescente submissão de artigos a periódicos e conferências de Ciência da Computação, destacando a dificuldade dos autores em selecionar os locais mais adequados para publicação. Diante desse cenário, a solução proposta é um SR baseado em conteúdo, que prioriza periódicos e conferências com base nos resumos dos manuscritos. A contribuição significativa do estudo inclui a cobertura de 66 importantes locais de publicação, a capacidade de recomendar áreas de pesquisa de ponta em tempo real e a implementação de um modelo eficiente de baixa complexidade computacional, permitindo respostas interativas *online* e atualizações automáticas do modelo de aprendizado.

A crescente quantidade de publicações científicas demanda sistemas automatizados de recomendação de artigos para auxiliar pesquisadores na busca por trabalhos relevantes. Kreutz e Schenkel(2022) discorrem sobre problemas como a necessidade de métodos eficazes de recomendação, a avaliação de sistemas existentes e a identificação de desafios em aberto, e propõem uma solução baseada na análise crítica de métodos, conjuntos de dados, avaliações e desafios identificados em trabalhos publicados entre janeiro de 2019 e outubro de 2021. As contribuições do artigo incluem uma visão abrangente e atualizada dos sistemas de recomendação de artigos científicos, fornecendo insights valiosos para pesquisadores interessados em SRs baseados em similaridade textual desestruturada.

Um contexto é apresentado por Afsar, Crump e Far (2021), no qual a provisão de informações a pacientes com câncer, especialmente a pacientes com câncer de próstata, é essencial para educá-los sobre suas condições de saúde e envolvê-los ativamente no processo de tomada de decisão compartilhada. Identifica-se a falta de recursos educacionais apropriados para esses pacientes, o que leva à proposta do sistema KERS (Knowledge-based Exploration on-demand article Recommender System), um SR de artigos sob demanda baseado em conhecimento. A solução proposta visa minimizar a exploração, ao mesmo tempo em que maximiza a satisfação a longo prazo dos usuários, aprendendo rapidamente seus interesses e recomendando os melhores artigos. As contribuições do artigo incluem uma abordagem inovadora para a recomendação de informações baseada em conhecimento, aplicável a sistemas de recomendação de manuscritos científicos, a arquiteturas de sistemas de recomendação com extração de textos na web e a sistemas de recomendação baseados em similaridade textual desestruturada. A Tabela 4.2 resume os trabalhos de recomendação de manuscritos científicos apresentados nesta seção.

Tabela 4.2 Comparativo de Sistemas de Recomendação de Manuscritos Científicos.

Autor (Ano)	Método / Técnica	Objetivo Principal	Relação com Recademy
Maruyama <i>et al.</i> (2023)	Processamento ativo e <i>online</i> .	Desenvolvimento de um sistema para fornecimento <i>online</i> de acesso às recomendações.	Alinha-se à estratégia de disponibilização ativa e em tempo real das recomendações geradas pelo motor.
Wang <i>et al.</i> (2018)	Baseado em conteúdo (análise de resumos).	Sistema de recomendação baseado na análise de resumos de manuscritos.	Fundamenta o fluxo de processamento <i>online</i> para o fornecimento de atualizações automáticas nas recomendações do sistema.
Kreutz e Schenkel (2022)	Revisão de métodos e <i>datasets</i> científicos.	Análise comparativa de métodos de recomendação e de consolidação de métricas de avaliação da literatura científica.	Subsidia a seleção e a definição das métricas de avaliação a serem utilizadas na validação experimental do Recademy.
Afsar <i>et al.</i> (2021)	Recomendação baseada em conhecimento.	Sistema KERS voltado ao engajamento dos usuários na tomada de decisão baseada em evidências.	Ilustra a aplicação da recomendação sob demanda para reduzir o esforço de busca ativa em sistemas de informação.

A partir da análise comparativa exposta na Tabela 4.2, é possível observar que, embora o campo de SRs científicos conte com propostas robustas para tarefas específicas (como a seleção criteriosa de veículos de publicação ou a utilização estratégica de redes de citações), ainda persiste uma lacuna no que tange à integração profunda com o perfil multifacetado do pesquisador e à oferta de itens que transcendam o artigo textual, como *software* e conjuntos de dados.

Essa contextualização técnica e acadêmica fundamenta a necessidade do sistema Recademy, que busca preencher tais lacunas ao automatizar a descoberta de trabalhos relevantes, sem exigir esforço ativo contínuo do usuário final. Desta forma, os trabalhos analisados fornecem o embasamento necessário para a consolidação das metas de solução estabelecidas neste estudo.

4.3 ARQUITETURA DE SISTEMAS DE RECOMENDAÇÃO COM EXTRAÇÃO DE TEXTOS NA WEB

No contexto deste trabalho, a ausência de consenso quanto às métricas necessárias à avaliação de SRs gera divergências. Para sanar este problema, Carvalho *et al.* (2018) propuseram o desenvolvimento de um *framework* para auxiliar no processo, utilizando as métricas mais populares e identificando características dos conjuntos de dados que possam afetar o desempenho dos sistemas. Fatores que diferenciam a pesquisa em questão de trabalhos anteriores relacionados incluem a possibilidade de caracterizar os *datasets* e a capacidade de se manter extensível à adição de novas métricas.

Zhang *et al.* (2019) oferecem uma revisão abrangente dos avanços em SRs com Aprendizado Profundo (AP), categorizando e resumindo mais de 100 estudos para orientar pesquisadores e profissionais interessados neste campo. Além de influenciar a arquitetura de SRs baseados em extração da *Web*, através da análise das vantagens e desvantagens das técnicas de AP para tarefas de recomendação, a proposta de uma classificação e esquema de organização dos estudos existentes e ênfase da importância de considerar a diversidade de fontes de dados como aprimoramento da eficácia destes sistemas, a pesquisa destaca as vantagens e desvantagens das técnicas de AP, fornecendo um guia para a escolha de redes neurais profundas. Com o objetivo de expandir os horizontes da pesquisa em SR, o artigo contribui para o avanço contínuo da área, promovendo inovações e orientando futuras investigações.

No contexto de sistemas de recomendação baseados em dados extraídos da web, a dispersão de informações (*data sparsity*) representa um desafio arquitetural crítico, visto que os perfis dos pesquisadores frequentemente apresentam lacunas ou dados incompletos. YU (2023) aborda este problema ao propor soluções para mitigar a dispersão em ambientes não supervisionados, fornecendo um *toolkit* projetado para otimizar a extração e a representação estruturada de matrizes esparsas. No escopo do Recademy, os conceitos levantados por YU (2023) fundamentam a arquitetura de processamento no *back-end*, justificando a implementação de mecanismos de agregação e armazenamento em *cache* na API REST. Essa abordagem permite que o servidor do sistema lide de forma eficiente com dados ruidosos provenientes da web, reduzindo a latência nas requisições e garantindo o desempenho do motor de recomendação sem onerar o lado do cliente.

Desafios de segurança e privacidade enfrentados pelos SRs foram abordados, destacando a importância de tecnologias como *blockchain*, IA explicável e computação de borda. Himeur *et al.* (2022) oferecem uma revisão abrangente das pesquisas recentes nesse campo, discutindo *frameworks* existentes, aplicações práticas e direções futuras. As contribuições incluem a análise de questões como confiança, autenticação, ataques maliciosos, justiça e viés, além de abordar a importância da preservação da privacidade e segurança em diferentes cenários de aplicação, como *e-commerce*, saúde, Internet das Coisas (IoT) e redes sociais.

Segurança e privacidade em SRs são aspectos de crescente preocupação, e um trabalho apresenta uma revisão abrangente das últimas tendências em ataques e defesas nesses sistemas, destacando a importância desses aspectos. García e Bellogín (2018) propõem uma visão abrangente das questões de segurança e privacidade, identificando direções futuras de pesquisa e contribuindo por meio da análise de ataques e defesas atuais, bem como a identificação de lacunas e desafios a serem abordados na área de SR.

A Tabela 4.3 apresenta uma análise com o objetivo de explicitar os dados utilizados pelos sistemas, iniciando pela identificação de características específicas dos *datasets* que podem impactar diretamente o desempenho dos algoritmos. Para maximizar a eficácia de modelos baseados em aprendizado profundo, a literatura enfatiza a importância de integrar uma ampla gama de fontes de dados. No entanto, o tratamento dessas informações enfrenta desafios críticos, como a escassez de dados (*data sparsity*), recorrente em modelos de aprendizado não supervisionado. Além disso, a gestão de dados exige atenção rigorosa à segurança e à preservação da privacidade do usuário, garantindo a integridade

das informações em domínios como saúde, IoT e redes sociais.

Tabela 4.3 Comparativo entre Arquitetura de Sistemas e Tratamento de Dados.

Autor (Ano)	Método / Técnica	Objetivo Principal	Relação com Recademy
Carvalho <i>et al.</i> (2018)	Análise de impacto de <i>datasets</i> .	Criar um <i>framework</i> extensível focado nas métricas populares que afetam o desempenho dos algoritmos.	A identificação de características dos <i>datasets</i> que afetam o desempenho dos SRs fundamenta a decisão do Recademy de construir um conjunto de dados personalizado.
Zhang <i>et al.</i> (2019)	Diversidade de fontes de extração.	Categorizar as vantagens e desvantagens de redes neurais e ressaltar a importância de fontes diversificadas.	Embasamento para o uso de múltiplas fontes na construção do <i>pool</i> temático (ORCID e DBLP operando em conjunto).
Yu (2023)	Gerenciamento de <i>data sparsity</i> .	Propor soluções baseadas em um <i>toolkit</i> para mitigar a dispersão de dados em ambientes não supervisionados.	Fundamenta a arquitetura de agregação e o uso de <i>cache</i> na API (<i>back-end</i>), garantindo eficiência no processamento de perfis com dados incompletos.
Himeur <i>et al.</i> (2022)	Privacidade, viés e segurança.	Revisar tecnologias como IA Explicável e computação de borda na mitigação de acessos não autorizados.	Direciona as diretrizes de privacidade e segurança na API do Recademy, orientando a manipulação anônima e o armazenamento seguro dos perfis no servidor.
García e Bellogín (2018)	Segurança em <i>frameworks</i> de recomendação.	Investigar vetores de ataque, defesas contemporâneas e falhas em estruturas que não preservam a privacidade.	Guia o planejamento arquitetural da API REST contra vetores de ataque em requisições online, garantindo a integridade do motor de recomendação.

4.4 SUMÁRIO

Neste capítulo, foram apresentados e analisados diversos trabalhos relacionados a três áreas de pesquisa associadas aos sistemas de recomendação. A revisão da literatura evidenciou a existência de um número significativo de iniciativas voltadas aos domínios educacionais e científicos. Entretanto, observou-se uma lacuna na incorporação do perfil do pesquisador como elemento central na geração de recomendações personalizadas. A partir dessa análise, foi possível identificar e adotar as melhores práticas reportadas na literatura, tanto na definição da arquitetura da plataforma quanto na seleção, parametrização e integração dos algoritmos de recomendação empregados no desenvolvimento da solução proposta.

RECADEMY - UM SISTEMA DE RECOMENDAÇÃO DE ARTIGOS CIENTÍFICOS

Neste capítulo, apresenta-se a arquitetura do sistema proposto para recomendação de artigos científicos relacionados à linha de pesquisa do pesquisador, marcando a transição crucial da teoria para a prática. Os conceitos de Sistema de Recomendação (SR) e a análise de trabalhos correlatos, explorados nos capítulos anteriores, se consolidam em uma solução concreta de engenharia de *software*. A proposta abrange a definição de um modelo de usuário, baseado em suas publicações e áreas de interesse, e de um modelo de recomendação híbrido capaz de identificar os artigos mais relevantes. Discutimos as principais funcionalidades e ferramentas tecnológicas utilizadas, incluindo as Interfaces de Programação de Aplicações (APIs) ORCID para a coleta de dados e uma API de metadados bibliográficos para a consulta de artigos relacionados em larga escala global. Ao final, são apresentados exemplos de uso da *interface* desenvolvida, bem como as tecnologias empregadas para garantir a eficiência do processo de recomendação e enfrentar diretamente o desafio da sobrecarga de informação.

Para facilitar a compreensão da modelagem formal e da lógica de ranqueamento distribuídas ao longo das próximas seções, a Tabela 5.1 consolida as principais notações, símbolos e variáveis empregados neste trabalho.

Tabela 5.1 Tabela de Notações utilizadas na Modelagem do Sistema Recademy.

Símbolo	Descrição
U	Conjunto de todos os usuários (pesquisadores) no sistema.
$\mathcal{P}$	Conjunto de itens (publicações científicas candidatas à recomendação).
$\theta(u)$	Perfil de um usuário $u \in U$, representado por um vetor de pesos de palavras-chave.
t_p, a_p, y_p, r_p	Atributos fundamentais de uma publicação p (Título, Autores, Ano e Tipo, respectivamente).
$\mathcal{P}_\tau$	Subconjunto de publicações candidatas recuperadas em uma rodada de busca.
p_{melhor}	Artigo candidato pertencente a $\mathcal{P}_\tau$ que maximiza o escore final de recomendação.
$Sem(p, \tau)$	Componente do escore que avalia a similaridade semântica (via Word2Vec).
$Ano(p)$	Componente do escore que avalia a atualidade temporal por meio de decaimento logarítmico.
$Cit(p)$	Componente do escore que avalia o impacto por meio do volume normalizado de citações.
$Rel(p)$	Componente do escore que avalia o fator de relevância ou de prestígio do veículo de publicação.
W_τ, W_p	Conjunto de termos extraídos do tópico do pesquisador e do título do artigo, respectivamente.
$sim(r_u, r_v)$	Medida de proximidade vetorial entre dois vetores de representação de palavras.
Δ_{max}	Janela temporal máxima considerada para a penalização de publicações antigas.
$CPY(p)$	Taxa de citações por ano de vida de uma publicação p (<i>Citations Per Year</i>).

5.1 ARQUITETURA

Para a apresentação das informações e a coleta de feedbacks dos usuários, foi desenvolvida uma *interface* web responsiva, configurada como um painel de avaliação dinâmico. Este recurso possibilita a exibição estruturada e legível para o ser humano das recomendações geradas, permitindo que os participantes avaliem instantaneamente a relevância de cada artigo. A aplicação interage diretamente com os serviços de *back-end* para autenticação e consulta do perfil do usuário por meio do identificador ORCID, registrando as avaliações diretamente na base de dados do sistema. A Figura 5.1 exibe as etapas percorridas pelo fluxo, iniciando na etapa 1, em que ocorre a requisição do perfil do usuário a partir da *interface* web, e finalizando com o retorno e a apresentação das publicações recomendadas na etapa 9.

A escolha da plataforma ORCID como fonte primária para a modelagem do perfil do pesquisador, em detrimento da Plataforma Lattes, fundamentou-se em critérios de viabilidade técnica e de acessibilidade para a integração. Enquanto a ORCID disponibiliza uma API pública, com documentação clara e um processo de autenticação simplificado para desenvolvedores, a Plataforma Lattes não oferece uma *interface* de programação aberta, o que exige processos de credenciamento que impõem barreiras significativas de tempo e esforço, incompatíveis com o escopo deste projeto. A ausência de uma API pública no Lattes implicaria a adoção de técnicas de *web scraping*, elevando substancialmente a complexidade do sistema em comparação à estrutura de dados padronizada da

ORCID. Adicionalmente, a *interface web* do Lattes emprega mecanismos de verificação (CAPTCHAs) para impedir o acesso automatizado; a tentativa de contorná-los demandaria recursos computacionais excessivos e acarretaria conflitos éticos, uma vez que violaria as diretrizes de proteção deliberadamente implementadas pela plataforma.




Figura 5.1 Diagrama de arquitetura cliente-servidor do sistema Recademy.

As operações lógicas centrais ocorrem no *back-end*, entre as etapas 3 e 8, nas quais o servidor centraliza o processamento: realiza a requisição do perfil do pesquisador, extrai os conceitos-chave de sua linha de pesquisa, consulta a base de dados global para coletar artigos candidatos, aplica o motor de pontuação multiplicativo e executa as técnicas de normalização e *re-ranking*. Este intervalo também abrange as integrações com serviços e bases de dados de organizações externas, bem como as estruturas de armazenamento persistente de dados. Com o objetivo de reduzir o tempo de resposta, o número de requisições efetuadas às dependências externas e o custo geral de processamento, foi implementado um cache baseado em estruturas de chave-valor (utilizando o Redis), que armazena temporariamente as respostas às consultas realizadas às APIs ORCID e às bases de dados bibliográficas.

5.2 PERFIL DO USUÁRIO

De modo a fornecer recomendações mais alinhadas às linhas de pesquisa recentes, o perfil do usuário é construído com base em informações provenientes dos trabalhos e publicações dos quais participou. Essas informações são coletadas principalmente pela API ORCID, na qual registros detalhados de publicações e colaborações dos usuários são centralizados. Utilizando esses dados, o sistema pode buscar artigos com temáticas e abordagens semelhantes, o que permite gerar recomendações de artigos mais relevantes para o usuário. Esse perfil é ajustado continuamente para refletir os novos interesses e descobertas do usuário ao longo do tempo, proporcionando uma experiência de recomendação alinhada

ao seu desenvolvimento acadêmico.

O perfil de usuário não é salvo no banco de dados e suas informações são recuperadas por meio das integrações em cada fluxo de recomendação. Essa escolha foi feita para garantir que as recomendações sejam sempre baseadas nos dados mais atualizados, eliminando a necessidade de sincronização manual. Essa característica traz a vantagem de flexibilizar o modelo, ao mesmo tempo em que reduz a possibilidade de as recomendações serem afetadas por informações desatualizadas. No entanto, isso também constitui um ponto de falha em caso de erro de comunicação com as integrações, o que pode interromper a geração de recomendações em tempo real e exigir que o sistema implemente estratégias de recuperação.

Seja U o conjunto de todos os usuários, I o conjunto de itens (publicações científicas), e $\theta(u)$ o perfil de um usuário $u \in U$, construído com base em suas interações passadas com itens de I . O perfil do usuário é definido por um vetor de características $\theta(u) = (w_1, w_2, \dots, w_n)$, em que cada w_i representa o peso de uma palavra-chave extraída de suas publicações (obtidas pela API ORCID). O sistema calcula a similaridade entre o perfil de um usuário e os itens recomendados utilizando uma métrica de proximidade semântica.

5.3 MODELO DO ITEM A SER RECOMENDADO

Para gerar uma lista de recomendações com base nas publicações, além de construir o perfil do usuário, é necessário construir o modelo do item, que representa uma publicação científica. Esse item possui um subconjunto de atributos obrigatórios e outro de atributos opcionais, que são incorporados quando disponíveis, tais como o nome do periódico ou da conferência, a editora, o tipo de acesso (aberto ou fechado) e a Identificador de Objeto Digital (DOI).

Formalmente, cada item ($p \in \mathcal{P}$) é representado por uma tupla de atributos que descrevem suas propriedades essenciais e complementares:

$$p = \langle t_p, a_p, y_p, l_p, \tau_p, p_p, e_p, \alpha_p, d_p, \dots \rangle,$$

em que t_p é o título da publicação; a_p é a lista de autores; y_p é o ano de publicação; l_p é o *link* de acesso à publicação; τ_p é o tipo de publicação, indicando se se trata de artigo de periódico, conferência, livro, capítulo ou outro formato científico. Como campos opcionais, são p_p que é o nome do periódico ou da conferência onde o trabalho foi publicado; e_p é a editora responsável pela publicação; α_p é o tipo de acesso; e d_p é o DOI. Poderá haver outros atributos opcionais além dos mencionados.

5.4 MODELO DE RECOMENDAÇÃO

De acordo com o Algoritmo 1, o processo de recomendação se inicia com a obtenção dos dados do usuário (linha 1) e com a inicialização das variáveis de controle (linhas 2-3). O sistema itera pelas fontes de dados (linha 4) e, para cada uma, verifica se provêm do serviço ORCID (linha 5). Em caso afirmativo, um resumo dos tópicos de interesse é gerado (linha 6). Caso a lista de tópicos não esteja vazia (linha 7), para cada tópico identificado (linha 8), consultas de busca são construídas (linha 9) e executadas contra

Algoritmo 1: Recomendação de trabalhos relacionados

Input: $id \in \text{String}$ (identificador do usuário)
Output: $\mathcal{P}$ (lista de publicações)

```

1  $U \leftarrow \text{usuário}(id)$ ;
2  $\mathcal{S} \leftarrow \emptyset$ ;
3  $\mathcal{P} \leftarrow \emptyset$ ;
4 foreach  $s \in U.\text{fontes}$  do
5   if  $s_{\text{serviço}} = \text{ORCID}$  then
6      $\mathcal{S} \leftarrow \text{resumo\_usuário}(s_{\text{url}})$ ;
7 if  $\mathcal{S} \neq \emptyset$  then
8   foreach  $\tau \in \mathcal{S}$  do
9      $\mathcal{T}(\tau) \leftarrow \text{construir\_consulta}(\tau)$ ;
10     $\mathcal{P}_{\tau} \leftarrow \emptyset$ ;
11    foreach  $q \in \mathcal{T}(\tau)$  do
12       $\mathcal{P}_q \leftarrow \text{buscar\_publicações}(q)$ ;
13       $\mathcal{P}_{\tau} \leftarrow \mathcal{P}_{\tau} \cup \mathcal{P}_q$ ;
14     $\mathcal{P}_{\tau} \leftarrow \{p \in \mathcal{P}_{\tau} : \text{publicações\_válidas}(p)\}$ ;
15     $p_{\text{melhor}} \leftarrow \emptyset$ ;
16    if  $\mathcal{P}_{\tau} \neq \emptyset$  then
17       $p_{\text{melhor}} \leftarrow \text{selecionar\_melhor}(\mathcal{P}_{\tau}, \tau, U)$ ;
18    if  $p_{\text{melhor}} \neq \emptyset$  then
19       $\mathcal{P} \leftarrow \mathcal{P} \cup \{p_{\text{melhor}}\}$ ;
20    if  $|\mathcal{P}| = 10$  then
21      return  $\mathcal{P}$ ;
22 return  $\mathcal{P}$ ;
  
```

a API OpenAlex para coletar publicações candidatas (linha 12). O conjunto obtido é unificado e, posteriormente, sanitizado (linha 14), o que remove itens inválidos. Se houver candidatos disponíveis (linha 16), a função de seleção é acionada para identificar a “melhor publicação” (linha 17). Se a publicação escolhida for válida e inédita (linha 18), ela é adicionada à lista de recomendações (linha 19). O processo verifica se o limite de **dez** sugestões foi atingido (linha 20) para retorno imediato (linha 21), ou continua até finalizar as fontes, retornando a lista final na linha 22.

Para garantir a seleção das publicações mais próximas do perfil do pesquisador, as métricas de proximidade vetorial foram utilizadas, de modo a selecionar palavras-chave com o maior nível de proximidade semântica entre as publicações retornadas pelas integrações e os trabalhos realizados pelo usuário.

Cabe esclarecer o papel do título e do resumo (abstract) no fluxo do sistema. A modelagem do perfil de preferências do usuário utiliza exclusivamente os títulos das publicações do pesquisador, dos quais são extraídas as palavras-chave que compõem o vetor $\theta(u)$; os resumos não participam da construção do perfil. Os resumos são utilizados na etapa de recuperação de candidatos junto ao OpenAlex. Registra-se, ainda, que a filtragem semântica sobre os resultados da API apresentou ruídos durante o desenvolvimento, o que constitui uma dificuldade operacional a ser considerada por trabalhos futuros que utilizem a mesma fonte de dados.

$$\text{simCosine}(u, v) = \frac{\sum_{i \in I_{uv}} r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i \in I_{uv}} r_{ui}^2} \sqrt{\sum_{i \in I_{uv}} r_{vi}^2}} \quad (5.1)$$

Na etapa *selecionar melhor* do algoritmo de recomendação, a seleção da melhor publicação, p_{melhor} , é realizada ao identificar, no conjunto de candidatas $\mathcal{P}_\tau$, a publicação que maximiza um *score* composto por quatro componentes normalizados no intervalo $[0, 1]$: similaridade semântica (Sem), ano de publicação (Ano), impacto por citações (Cit) e prestígio do veículo de publicação (Rel). A combinação multiplicativa desses fatores garante que uma publicação só obtenha pontuação elevada se for simultaneamente relevante, recente, impactante e publicada em veículo de qualidade:

$$p_{\text{melhor}} = \arg \max_{p \in \mathcal{P}_\tau} \text{Sem}(p, \tau) * \text{Ano}(p) * \text{Cit}(p) * \text{Rel}(p) \quad (5.2)$$

O componente de **similaridade semântica** $\text{Sem}(p, \tau)$ é calculado por meio da comparação par a par entre os termos extraídos do tópico do pesquisador, W_τ , e os termos do título do artigo candidato, W_p , utilizando modelos de *word embedding*. O valor final corresponde à média das métricas de similaridade de todos os pares de palavras:

$$\text{Sem}(p, \tau) = \frac{1}{|W_\tau| \cdot |W_p|} \sum_{w_\tau \in W_\tau} \sum_{w_p \in W_p} \text{sim}(w_\tau, w_p) \quad (5.3)$$

onde $\text{sim}(r_u, r_v)$ representa a similaridade de cosseno entre os vetores de duas palavras r_u e r_v :

$$\text{sim}(r_u, r_v) = \frac{r_u \cdot r_v}{\|r_u\| \|r_v\|} = \frac{\sum_{i=1}^n r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i=1}^n r_{ui}^2} \sqrt{\sum_{i=1}^n r_{vi}^2}} \quad (5.4)$$

O componente de **ano de publicação** $\text{Ano}(p)$ penaliza artigos mais antigos por meio de um decaimento logarítmico, normalizando a idade da publicação em relação à janela temporal máxima considerada ($\Delta_{\max}$):

$$\text{Ano}(p) = \max\left(0, 1 - \frac{\ln(\text{idade}(p) + 1)}{\ln(\Delta_{\max} + 1)}\right) \quad (5.5)$$

Na implementação, a janela temporal máxima ($\Delta_{\max}$) é fixada em cinco anos. Dessa forma, uma publicação do ano de corte recebe o valor máximo (1,0), e o valor decresce logaritmicamente à medida que a publicação envelhece, atingindo zero no limite inferior da janela. No experimento offline, conduzido sobre o corpus DBLP-v10, essa janela corresponde ao intervalo de 2013 a 2017. O registro explícito desses limites é necessário para a reprodução do experimento, uma vez que o valor do fator Ano depende diretamente do intervalo considerado.

O componente de **impacto por citações** $\text{Cit}(p)$ normaliza o número de citações por ano de vida da publicação (CPY) utilizando normalização *Min-Max* local em relação ao conjunto de candidatos da rodada, eliminando a necessidade de limiares globais arbitrários:

$$\text{CPY}(p) = \frac{n_{\text{citações}}(p)}{\max(1, \text{ano_atual} - \text{ano}(p) + 1)} \quad \text{Cit}(p) = \frac{\text{CPY}(p) - \text{CPY}_{\min}}{\text{CPY}_{\max} - \text{CPY}_{\min}} \quad (5.6)$$

Por fim, o componente de **fator de relevância do veículo de publicação** (Rel) avalia o prestígio acadêmico do periódico ou da conferência onde o artigo foi publicado. Esta variável confere flexibilidade à arquitetura, podendo ser instanciada com diferentes métricas globais de impacto, como o *Impact Factor* (JCR) ou o *SCImago Journal Rank* (SJR). No escopo de validação deste trabalho, optou-se por instanciar $\text{Rel}(p)$ retornando uma pontuação proporcional ao estrato Qualis CAPES do veículo, de acordo com o registro mantido pelo Programa de Pós-Graduação em Ciência da Computação da PUCRS¹, com valores mapeados linearmente no intervalo [0, 1].

A natureza multiplicativa do *score* final (Equação 5.2) é uma escolha de *design* deliberada: qualquer componente com valor próximo de zero, seja por baixa relevância semântica, ano de publicação distante da janela temporal considerada, ausência de citações ou publicação em veículo sem classificação, reduz o *score* geral à proximidade de zero, independentemente do desempenho dos demais fatores. Isso impede que artigos muito citados, mas semanticamente irrelevantes, dominem o *ranking* de recomendações.

O método de obtenção e avaliação de itens do sistema pode ser adaptado para utilizar diversas métricas de proximidade semântica, conforme as necessidades específicas do contexto de aplicação. A arquitetura do sistema Recademy foi projetada com essa flexibilidade em mente, permitindo ajustar o componente de similaridade semântica a diferentes tipos de conteúdo acadêmico, como artigos, livros, datasets ou pré-publicações, e a diferentes perfis de usuários, considerando suas áreas de interesse, histórico de pesquisa e padrões de leitura.

¹<<https://ppgcc.github.io/dissentPPGCC/pt-BR/qualis>>

5.5 INTERFACE DE AVALIAÇÃO E FUNCIONALIDADES

Para a coleta de dados do experimento, foi desenvolvida uma interface web de avaliação², acessível diretamente pelo navegador, sem necessidade de instalar componentes adicionais. A aplicação foi construída com HTML, CSS e JavaScript, integrada ao *back-end* Python via API REST, e disponibilizada publicamente durante o período de coleta de dados.

O fluxo de interação do participante ocorre em duas etapas. Na primeira, ilustrada na Figura 5.2, o usuário informa seu identificador ORCID no formulário disponível e aciona a geração de recomendações. O sistema consulta o perfil do pesquisador via API ORCID, extrai os conceitos-chave de suas publicações, realiza buscas na API bibliográfica e aplica o motor de pontuação multiplicativo, retornando uma lista com até 10 artigos recomendados.

1. What's trending in difference-in-differences? A synthesis of the recent econometrics literature

Autores: Jonathan Roth, Pedro H. C. Sant'Anna, Alyssa Bilinski, John Poe | **Ano:** 2023 | **Local:** Journal of Econometrics

DOI: <https://doi.org/10.1016/j.jeconom.2023.03.008>

Qual a relevância deste artigo para o seu tema?

1 2 3 4 5

Comentário opcional sobre por que deu essa nota...

2. Enhancing crop recommendation systems with explainable artificial intelligence: a study on agricultural decision-making

Autores: Mahmoud Y. Shams, Samah A. Gamel, Fatma M. Talaat | **Ano:** 2024 | **Local:** Neural Computing and Applications

DOI: <https://doi.org/10.1007/s00521-023-09391-2>

▼ Ver resumo

Qual a relevância deste artigo para o seu tema?

1 2 3 4 5

Comentário opcional sobre por que deu essa nota...

Figura 5.2 Interface web de avaliação do sistema Recademy utilizada no experimento.

Na segunda etapa, os artigos recomendados são exibidos com título clicável (redirecionando para o DOI do artigo), lista de autores, veículo de publicação e ano. Para cada artigo, o participante atribui uma nota de relevância em uma escala de 1 a 5, em que 1 representa ausência de relevância e 5, relevância máxima em relação à sua linha de pesquisa. Ao finalizar, opcionalmente, deixa comentários sobre as recomendações recebidas. As avaliações são registradas diretamente na base de dados MongoDB do sistema.

5.6 RECOMENDAÇÃO EM AÇÃO

O processo de recomendação é iniciado pelo participante ao informar seu identificador ORCID na interface web de avaliação. A requisição é enviada ao *back-end*, que autentica o usuário e recupera, por meio da API ORCID, os títulos das publicações às quais o pesquisador contribuiu.

²<https://paperman-omega.vercel.app/>

A partir dos títulos recuperados, o sistema extrai bigramas representativos, que são utilizados como consultas de busca na API bibliográfica. Para cada consulta, uma lista de artigos candidatos é retornada e acumulada. Os parâmetros utilizados nas buscas e seus respectivos resultados são armazenados em cache no Redis, o que proporciona ganhos de escalabilidade e reduz a latência para usuários com perfis de pesquisa semelhantes.

Após o retorno das listas de publicações candidatas, cada uma passa por uma etapa de pós-processamento, que inclui a normalização dos dados, a remoção de entradas em idiomas não suportados, a filtragem de artigos já recomendados ao usuário e a limpeza de *stopwords*. Os artigos remanescentes são então pontuados pelo motor de *scoring* multiplicativo descrito na Equação 5.2, composto pelos fatores de similaridade semântica, ano de publicação, impacto por citações e prestígio do veículo. A Figura 5.3 apresenta um exemplo das informações manipuladas e processadas pela API ao longo deste fluxo.

```
{
  "rank": 1,
  "title": "What's trending in difference-in-differences? A synthesis of the
    recent econometrics literature",
  "year": 2023,
  "venue": "Journal of Econometrics",
  "authors": [
    "Jonathan Roth",
    "Pedro H. C. Sant'Anna",
    "Alyssa Bilinski",
    "John Poe"
  ],
  "n_citation": 1623,
  "doi": "https://doi.org/10.1016/j.jeconom.2023.03.008",
  "scores": {
    "score_total": 0.0078,
    "score_sem": 0.2193,
    "score_rec": 0.2263,
    "score_cit": 0.2092,
    "qua_term": 0.75,
    "qua_raw": 0.75
  }
}
```

Figura 5.3 Exemplo de item em lista de recomendações gerada pela API Recademy.

Ao final do processamento, os dez artigos com maior *score* são selecionados e retornados à interface web, onde são exibidos ao participante de forma estruturada e legível para o ser humano, conforme descrito na Seção 5.5. O participante então avalia cada recomendação em uma escala de 1 a 5, e as avaliações são registradas diretamente na base de dados MongoDB do sistema para posterior análise.

5.7 TECNOLOGIAS

A aplicação foi construída com base em um *back-end* Python 3.11, utilizando o *framework* FastAPI para a criação e estruturação de uma API que obedece aos princípios da arquitetura de *software* REST. Dentre as bibliotecas de maior relevância para os fluxos do sistema, destacam-se Pandas, NLTK, Gensim e Pydantic. O projeto também conta com integrações a serviços externos. Para comunicação com o *back-end* e para a exibição dos componentes, a interface web utiliza HTML, CSS e JavaScript. A persistência de dados foi projetada com base em um banco de dados MongoDB, que consiste em duas coleções. Uma delas possui dados dos usuários, como fontes de recuperação de informações que comporão o perfil utilizado nas recomendações e em seus respectivos resultados. A outra contém informações sobre locais de publicação, como periódicos e conferências. Estas informações também alimentam o cache do Redis. Toda a estrutura foi hospedada em um Servidor Virtual Privado (VPS) com o sistema operacional Ubuntu, versão 22.04.

5.8 SUMÁRIO

Neste capítulo foram apresentados os principais aspectos da estratégia de recomendação proposta, incluindo a arquitetura da plataforma, as tecnologias empregadas, as formulações matemáticas utilizadas no processo de recomendação e exemplos dos resultados produzidos pela API. Além disso, foram introduzidas as notações matemáticas que fundamentam a modelagem e o aperfeiçoamento de SRs, as quais subsidiaram o desenvolvimento da plataforma e a construção dos modelos de usuário e dos objetos de recomendação.

AVALIAÇÃO EXPERIMENTAL PRELIMINAR

Este capítulo apresenta a validação experimental do Sistema de Recomendação (SR) Recademy sob duas perspectivas complementares: um experimento *offline* controlado, utilizando o corpus DBLP-v10 com 49 autores, e um experimento *online* no formato de Teste A/B cego com 27 pesquisadores reais. Ambos os experimentos visam investigar a eficácia do sistema em gerar recomendações precisas e alinhadas ao perfil acadêmico dos usuários.

6.1 PROTOCOLO DE AVALIAÇÃO

Ambos os experimentos compartilham o mesmo conjunto de métricas de avaliação quantitativa. Para o cálculo das métricas, definem-se dois conjuntos fundamentais: g representa o conjunto de **artigos relevantes** (gabarito, ou *ground truth*); e r representa o conjunto de **artigos efetivamente recomendados** pelo sistema.

6.1.1 Métricas de Avaliação

A precisão é calculada como a proporção de artigos recomendados que são de fato relevantes:

$$\text{precision} = \frac{|g \cap r|}{|r|} \quad (6.1)$$

O *Mean Reciprocal Rank* (MRR) mede a posição média do primeiro artigo relevante na lista de recomendações:

$$\text{MRR} = \frac{1}{m} \sum_{i=1}^m \frac{1}{\text{rank}_i} \quad (6.2)$$

onde m representa o total de consultas e rank_i indica a posição do primeiro artigo relevante na i -ésima recomendação. O *Mean Average Precision* (MAP) agrega a precisão em cada posição relevante da lista:

$$\text{MAP} = \frac{1}{m} \sum_{i=1}^m \frac{1}{|g_i|} \sum_{j=1}^{|g_i|} P@k_{ij} \quad (6.3)$$

onde $|g_i|$ é o número de artigos relevantes para o i -ésimo usuário e $P@k_{ij}$ corresponde à precisão até a k -ésima posição do j -ésimo artigo relevante. Por fim, o *Normalized Discounted Cumulative Gain* (nDCG) avalia a qualidade do ordenamento, penalizando artigos relevantes posicionados em posições mais baixas. Valores próximos de 1 indicam que os artigos mais relevantes estão consistentemente no topo da lista.

6.2 AVALIAÇÃO VIA EXPERIMENTO OFFLINE

Para complementar os resultados da Avaliação Experimental e estabelecer uma classificação quantitativa e controlada do sistema de recomendação, conduziu-se um experimento *offline*. Esta abordagem permite validar a eficácia do modelo sem a necessidade de interação direta com o usuário final, utilizando um conjunto de dados históricos como base para simular o processo de recomendação e aferir seu *performance*. O processo pode ser dividido em quatro etapas principais: definição do conjunto de dados, geração de recomendações, cálculo de métricas de avaliação e análise dos resultados.

6.2.1 Conjunto de Dados

A primeira fase do experimento consistiu na criação de um conjunto de dados de teste robusto, utilizando o DBLP-v10¹ com aproximadamente 1,38 GB de registros de publicações. O corpus foi utilizado localmente em formato CSV, estratégia adotada para possibilitar a manipulação em larga escala, sem a necessidade de mecanismos de *rate limiting* ou de acesso a Interfaces de Programação de Aplicações (APIs) externas durante a fase de busca por candidatos.

Para a composição do conjunto experimental, foram selecionados **49 autores** com mais de 30 publicações registradas no corpus, critério adotado para garantir que cada perfil dispusesse de dados suficientes para o protocolo *Hold-Out* com margem de segurança. O experimento foi estruturado sob o protocolo *Hold-Out* com *Candidate Injection*: para cada autor, os primeiros 20 trabalhos publicados no período considerado foram utilizados como conjunto de treino, servindo de base para a construção do perfil de interesse do pesquisador. Os 10 trabalhos seguintes foram injetados artificialmente na lista de candidatos como gabarito (*ground truth*), permitindo mensurar com precisão a capacidade do sistema de recuperar publicações relevantes. A janela temporal do experimento foi delimitada entre 2013 e 2017, a fim de simular um cenário controlado de avaliação retroativa. A Tabela 6.1 resume a configuração do experimento offline detalhada nesta seção.

¹<https://www.kaggle.com/datasets/nechbamohammed/research-papers-dataset>

Tabela 6.1 Configuração do Experimento Offline.

Parâmetro	Valor
Corpus	DBLP-v10
Tamanho do corpus	$\approx 1,38$ GB (formato CSV)
Critério de seleção de autores	Mínimo de 30 publicações no corpus
Autores avaliados	49
Protocolo	Hold-Out com Candidate Injection
Conjunto de treino (por autor)	20 publicações
Conjunto de gabarito (por autor)	10 publicações
Candidatos por pool	≈ 45 (após filtros de ano e idioma)
Janela temporal	2013–2017
Idiomas considerados	Português e inglês
Modelos avaliados	4 (Baseline Aleatório, Baseline Semântico, Multiplicativo, Aditivo)
Critério de relevância	Coautoria

6.2.2 Metodologia

Uma vez estabelecido o conjunto de autores para a avaliação, o sistema Recademy conduziu um processo metodológico rigoroso para gerar recomendações personalizadas. Os perfis temáticos de cada autor foram construídos a partir de seus títulos de publicações pré-carregados em memória, a partir do arquivo de dados experimentais, dispensando chamadas à API do ORCID nesta etapa. Esta escolha garantiu a reprodutibilidade do experimento e a eliminação de variáveis externas relacionadas à disponibilidade de serviços de terceiros.

Com o perfil temático estabelecido, o sistema construiu, para cada título de treino, um *pool* de candidatos por amostragem aleatória: 90 artigos foram sorteados uniformemente do corpus DBLP-v10, aos quais foram adicionados os 10 artigos do gabarito. Após os filtros de janela temporal e de idioma, restaram, em média, cerca de 45 candidatos por rodada, compondo o pool efetivamente pontuado. Essa estratégia elimina o viés de pré-filtragem textual e simula um cenário de descoberta mais desafiador, no qual o motor de *scoring* precisa identificar os artigos relevantes exclusivamente por meio da fórmula de ranqueamento.

Na etapa de ranqueamento, quatro estratégias de pontuação foram comparadas, definidas a partir de um processo incremental de composição do modelo. Partiu-se de uma abordagem puramente semântica e, progressivamente, foram incorporados os fatores Ano, Cit e Rel, até se alcançar a fórmula multiplicativa completa adotada pelo sistema. A Tabela 6.2 descreve cada estratégia avaliada.

Tabela 6.2 Estratégias de pontuação avaliadas no experimento offline.

Estratégia	Componentes	Descrição
Baseline Aleatório	—	Ordenação randômica dos candidatos; piso de comparação
Baseline Semântico	Sem	Proximidade vetorial entre perfil do autor e artigo candidato
Multiplicativo	Sem, Ano, Cit, Rel	Combinação multiplicativa dos quatro fatores; principal hipótese experimental deste trabalho
Aditivo	Sem, Ano, Cit, Rel	Combinação aditiva dos mesmos quatro fatores, também proposta neste trabalho como alternativa de comparação

Uma observação metodológica relevante diz respeito aos fatores acadêmicos do escore. O corpus DBLP-v10 disponibiliza contagens de citações para os artigos indexados. Cerca de 72,4% do corpus e 55,1% dos registros na janela 2013–2017 possuem ao menos uma citação registrada, de modo que o componente $Cit(p)$ operou com dados reais em todas as rodadas de avaliação. O fator de prestígio $Rel(p)$ também foi aplicado a todos os candidatos, instanciado a partir da tabela Qualis CAPES. Sua cobertura sobre o corpus, contudo, é parcial para veículos internacionais, e o efeito dessa característica sobre os resultados é analisado na Seção 6.2.4

6.2.3 Métricas de Avaliação

A etapa final do experimento *offline* consistiu em calcular métricas de *performance* para avaliar a qualidade das recomendações. Adotou-se como critério de relevância a coautoria: uma recomendação foi considerada acerto quando o autor-alvo constava como autor ou coautor do artigo recomendado.

Cogitou-se ampliar esse gabarito com dois indicadores adicionais extraídos do grafo de citações do corpus: os casos em que o autor-alvo já havia citado o artigo recomendado e os casos em que o artigo recomendado citava algum trabalho do autor-alvo. Na prática, porém, esses indicadores quase não alteraram o conjunto de acertos já obtido pela coautoria, registrando no máximo uma ocorrência isolada em um dos modelos avaliados, e por isso as métricas apresentadas na Seção 6.2.4 baseiam-se essencialmente nesse critério.

6.2.4 Resultados

Os resultados do experimento *offline* são apresentados na Figura 6.1, que consolida as métricas $P@K$, $MRR@K$ e $nDCG@10$ para os quatro modelos avaliados nos 49 autores do corpus DBLP-v10.

Entre as duas estratégias que incorporam o fator de prestígio $Rel(p)$, o modelo Multiplicativo superou o Aditivo em todas as métricas, com ganhos de 20,9% em $P@3$ (0,197 contra 0,163) e 25,3% em $MRR@3$ (0,371 contra 0,296). Ainda assim, nesta etapa ambas ficaram abaixo dos dois baselines: o Multiplicativo alcançou $P@3$ de 0,197, contra 0,265 do Baseline Semântico e 0,231 do Baseline Aleatório, ocupando a terceira posição entre os quatro modelos. Como se detalha adiante, esse resultado não reflete uma ordenação de baixa qualidade, e sim uma limitação estrutural da forma multiplicativa do escore, em




Figura 6.1 Comparativo de métricas dos modelos de *scoring* no experimento *offline* ($N = 49$). O número de acertos absolutos (*hits*) por modelo foi: Baseline Aleatório, 47/49; Baseline Semântico, 42/49; Multiplicativo, 34/49; e Aditivo, 30/49.

que a ausência de um único fator anula o candidato. O **Baseline Aleatório** registrou o maior número de acertos absolutos (47/49 autores), fenômeno explicado pelo *Efeito Pool Denso*: com 10 artigos gabarito injetados em um pool médio de 45 candidatos, aproximadamente 22% do pool já corresponde ao gabarito, inflando artificialmente os acertos do modelo aleatório. Este efeito tende a desaparecer em cenários com corpora abertos e pools de candidatos de maior escala.

O modelo **Baseline Semântico**, baseado exclusivamente na similaridade semântica, obteve os melhores resultados entre os modelos não aleatórios nesta etapa, com P@3 de 0,265 e MRR@3 de 0,449. Esse resultado decorre da cobertura da tabela Qualis sobre o conjunto de gabarito: por não empregar o fator de prestígio $Rel(p)$, o modelo permanece elegível a todos os artigos-alvo, inclusive aos publicados em veículos que não constam da tabela. Os modelos que incorporam $Rel(p)$ de forma multiplicativa não dispõem dessa liberdade, uma vez que um veículo ausente da tabela zera o escore do candidato. No experimento *online* (Seção 6.3), em que os artigos candidatos foram recuperados via API do OpenAlex e provieram majoritariamente de veículos indexados, o modelo Multiplicativo superou o Baseline Semântico em cinco das seis métricas avaliadas.

O desempenho abaixo do esperado do modelo Multiplicativo nesta etapa tem explicação direta na forma como o escore é composto. Dos 490 artigos que compõem o gabarito, 225 foram publicados em veículos que não constam da tabela Qualis e, por isso, recebem $Rel(p) = 0$. Como o escore final multiplica os quatro fatores, basta que um deles seja zero para anular todo o resultado: esses artigos acabam com pontuação nula e vão parar

no fim da lista, por mais próximos que estejam do perfil do autor. Não é que o modelo os classifique mal, é que ele simplesmente não consegue alcançá-los. Vale notar que o componente de citações funcionou sem problemas nesta etapa, com dados reais extraídos do corpus.

```
{
  "author": "Yuan-Fang Li",
  "hits_at_10": 5,
  "first_hit_position": 1,
  "metrics_by_k": {
    "k3": { "precision": 0.667, "mrr": 1.0, "ndcg": 0.765 },
    "k5": { "precision": 0.600, "mrr": 1.0, "ndcg": 0.699 },
    "k10": { "precision": 0.500, "mrr": 1.0, "ndcg": 0.918 }
  },
  "recommendations": [
    {
      "title": "Towards Meta-Reasoning for Ontologies: A Roadmap",
      "year": 2016,
      "venue": "European Conference on Artificial Intelligence",
      "is_hit": true,
      "hit_type": "coauthor",
      "scores": { "score": 0.4476, "sem": 0.4476, "qua_raw": 0.75 }
    }
  ]
}
```

Figura 6.2 Exemplo de recomendação relevante no início da lista.

6.3 EXPERIMENTO ONLINE

O experimento teve como objetivo avaliar a efetividade do sistema proposto, retomando as questões de pesquisa enunciadas na Seção 1.4 e verificando em que medida o sistema Recademy é capaz de gerar recomendações precisas, alinhadas ao título de pesquisa informado por cada participante.

6.3.1 Metodologia

O processo de avaliação inicia-se com a elaboração de recomendações personalizadas para cada pesquisador participante. Para este experimento, o perfil de cada participante foi representado pelo título da sua principal linha de pesquisa, informado no formulário de coleta, a partir do qual o sistema gerou a lista de artigos científicos. Estas recomendações são apresentadas por meio da interface do sistema, com título, autores, ano de publicação, venue e tipo de acesso.

Para capturar a percepção de cada sugestão, o pesquisador avalia a relevância de cada artigo em uma escala Likert de 5 pontos, em que 1 indica “Nada relevante” e 5 indica “Muito relevante”, conforme ilustrado na Figura 5.2. Opcionalmente, o participante pode fornecer comentários qualitativos sobre a utilidade das recomendações. As avaliações e os metadados são armazenados para análise posterior.

Com o objetivo de avaliar comparativamente o impacto da estratégia de pontuação adotada, o experimento foi conduzido sob o formato de Teste A/B cego com 27 pesquisadores recrutados por formulário voluntário. A Tabela 6.3 sintetiza a configuração

completa do experimento online. Do conjunto de pesquisadores que responderam ao formulário, o autor deste trabalho, responsável pelo desenvolvimento do sistema, foi excluído das análises para evitar viés de avaliação, resultando nos 27 participantes considerados. Cada participante forneceu seu nome e o título de sua principal linha de pesquisa e recebeu dois lotes de 10 recomendações: a **Lista 1** (abordagem multiplicativa, combinando proximidade semântica, Qualis e atualidade temporal) e a **Lista 2** (*Baseline Semântico*, baseada exclusivamente em proximidade vetorial). A apresentação foi realizada de forma cega, garantindo a imparcialidade das avaliações.

Tabela 6.3 Configuração do Experimento Online (Teste A/B).

Parâmetro	Valor
Participantes	27 pesquisadores
Recrutamento	Formulário voluntário
Entrada do usuário	Nome e título da linha de pesquisa (coletados por planilha)
Formato	Teste A/B cego
Recomendações por lista	10 artigos
Listas por participante	2 (Lista 1 e Lista 2)
Modelos avaliados	Multiplicativo e Baseline Semântico
Fonte dos candidatos	API OpenAlex (busca pelo título informado)
Critério de relevância	Avaliação Likert ≥ 3 (escala de 1 a 5)
Coleta de dados	Formulário de avaliação + feedback qualitativo

6.3.2 Métricas de Avaliação

Para o experimento *online*, a relevância de cada recomendação foi determinada com base na avaliação atribuída pelo participante em escala Likert de 1 a 5, sendo considerados relevantes os artigos com nota igual ou superior a 3. As métricas quantitativas utilizadas para mensurar a qualidade das recomendações estão definidas na Seção 6.1.1.

6.3.3 Conjunto de dados

Para o experimento *online*, a entrada de cada participante foi o título da sua principal linha de pesquisa, informado no formulário de coleta. A partir desse título, o sistema extraiu os bigramas representativos utilizados nas consultas à API bibliográfica, gerando as duas listas de recomendações avaliadas. A opção por essa entrada única, em vez do histórico de publicações do ORCID, deve-se a dois fatores: parte dos participantes eram pesquisadores em início de carreira, ainda sem histórico de publicações consolidado, e, do ponto de vista experimental, o uso de uma mesma representação de perfil para as duas listas garante que a estratégia de pontuação seja a única variável entre as condições comparadas. Cada perfil analisado é composto, portanto, por um único título de pesquisa. A modelagem de perfil a partir do histórico acadêmico completo, objeto da QP1,

é exercitada no experimento *offline* (Seção 6.2), em que cada perfil é construído a partir de 20 títulos de publicações reais do autor.

6.3.4 Resultados

Os resultados do experimento são apresentados em duas dimensões complementares: as métricas automáticas de ranqueamento, calculadas com base nas avaliações Likert atribuídas pelos participantes (considerando nota ≥ 3 como relevante), e as médias do questionário pós-avaliação, que capturam a percepção subjetiva dos pesquisadores sobre cada lista de recomendações.

A Figura 6.3 apresenta as métricas de ranqueamento agregadas para as duas abordagens avaliadas no experimento.




Figura 6.3 Métricas de ranqueamento agregadas do Teste A/B ($n = 27$): Lista 1 (Multiplicativo) *versus* Lista 2 (Baseline Semântico). A média das notas Likert atribuídas (escala 1–5) foi de 2,71 para a Lista 1 e 2,24 para a Lista 2.

A Figura 6.4 apresenta as médias por dimensão do questionário pós-avaliação, aplicado ao final do experimento, na escala Likert de 1 a 5.

Conforme evidenciado nas Figuras 6.3 e 6.4, a Lista 1 (abordagem multiplicativa) obteve desempenho superior em cinco das seis medidas comparadas, com destaque para P@5 (0,4889 contra 0,3481) e MAP (0,5890 contra 0,5080). A única exceção foi o nDCG, no qual a abordagem baseada na similaridade de cosseno registrou um valor superior (0,8930 contra 0,8485), diferença que, conforme discutido na Seção 6.3.6, não deve ser interpretada como evidência de desempenho superior. Na dimensão subjetiva, a Lista 1 superou a Lista 2 em todas as cinco dimensões do questionário, com diferença




Figura 6.4 Médias do questionário de percepção subjetiva por dimensão ($n = 27$), na escala Likert de 1 a 5. A linha tracejada indica o limiar de relevância (nota 3).

mais expressiva na atualidade (**3,33** contra 2,48) e na precisão (**2,52** contra 1,89).

Do ponto de vista de custo computacional, o tempo de geração das recomendações foi registrado para cada um dos 27 participantes. O modelo Multiplicativo consumiu, no total, 616 segundos (10,3 minutos), contra 640 segundos (10,7 minutos) do Baseline Semântico, com médias por participante de 22,8 e 23,7 segundos, respectivamente. Os fatores adicionais da fórmula multiplicativa não introduziram sobrecarga relevante frente ao baseline puramente semântico, e o tempo de geração permaneceu equivalente entre as duas abordagens.

6.3.5 Discussão

Os resultados do Teste A/B indicam que a abordagem multiplicativa (Lista 1) apresentou desempenho superior à baseada exclusivamente na similaridade de cosseno (Lista 2) na maioria das métricas avaliadas. A melhoria mais expressiva foi observada na precisão das primeiras posições da lista: a P@5 da Lista 1 foi cerca de 40% superior à da Lista 2 (0,4889 contra 0,3481), diferença estatisticamente significativa, o que indica que a fórmula multiplicativa posiciona artigos genuinamente relevantes no topo das recomendações com maior frequência. O MRR, por outro lado, foi apenas numericamente favorável à Lista 1 (0,6355 contra 0,5948), sem diferença estatisticamente significativa, de modo que não se pode afirmar que o primeiro item relevante apareça sistematicamente em posição mais alta em uma das abordagens.

Na dimensão subjetiva, a Lista 1 superou a Lista 2 em todas as cinco dimensões do questionário pós-avaliação. A diferença mais acentuada foi observada na atualidade

(3,33 contra 2,48), o que valida diretamente a contribuição do fator temporal presente na fórmula multiplicativa: ao penalizar artigos mais antigos, o sistema tende a recomendar publicações mais recentes, percebidas pelos pesquisadores como mais relevantes ao estado da arte de suas áreas. A dimensão de precisão também apresentou diferença expressiva (2,52 contra 1,89), corroborando os resultados das métricas automáticas de P@5 e MAP.

A única métrica em que a Lista 2 apresentou um valor superior foi o nDCG (0,8930 versus 0,8485). Conforme detalhado na Seção 6.3.6, a forma como essa métrica foi calculada afeta apenas a ordenação interna de cada lista, e não a qualidade dos itens recomendados. Por essa razão, a diferença observada no nDCG entre as duas abordagens não é interpretada como evidência de desempenho superior de nenhum dos modelos.

Em relação às limitações identificadas, a dependência de plataformas externas para a geração de recomendações constitui um fator de risco para a disponibilidade do sistema. Em caso de intermitência nos serviços consultados, o fluxo de recomendações pode ser interrompido, salvo quando as informações estiverem presentes no *cache*. Adicionalmente, o problema de *cold start* afeta o sistema Recademy: participantes cujo título de pesquisa apresenta terminologia muito restrita ou pouco representada no corpus tendem a receber recomendações menos alinhadas ao seu perfil acadêmico. Esses aspectos apontam para oportunidades de aprimoramento nas iterações futuras do sistema.

6.3.6 Limitações

Os experimentos conduzidos apresentam algumas limitações que devem ser consideradas na interpretação dos resultados. No que diz respeito ao experimento offline, o corpus DBLP-v10 possui um pool de candidatos relativamente denso: com 10 artigos gabarito injetados em um pool médio de 45 candidatos, aproximadamente 22% do pool já corresponde ao gabarito (*Efeito Pool Denso*). Esse desequilíbrio inflaciona artificialmente os acertos do Baseline Aleatório e limita a capacidade discriminativa das métricas de precisão. Em cenários com corpora abertos e pools de maior escala, esse efeito tende a ser atenuado.

As comparações do experimento *online* foram submetidas ao teste de postos sinalizados de Wilcoxon para amostras pareadas, adequado ao delineamento adotado, no qual cada participante avalia as duas listas. Sete das dez comparações apresentaram diferença estatisticamente significativa em favor do modelo multiplicativo ($p < 0,05$), com destaque para a dimensão de atualidade, a precisão medida em P@10 e a média das notas atribuídas. Três comparações não alcançaram significância: MRR, MAP e a dimensão de diversidade, de modo que as afirmações relativas ao MRR devem ser lidas como tendência observada, e não como diferença estabelecida. No experimento *offline*, o mesmo teste não indicou vantagem estatisticamente significativa do modelo multiplicativo sobre os *baselines*, resultado coerente com a limitação de cobertura do Qualis discutida na Seção 6.2.4.

Vale explicar por que o nDCG se comporta dessa forma neste experimento, já que o resultado decorre da maneira como ele é calculado. Para normalizar cada lista, o nDCG a compara com o seu próprio ideal, isto é, com os mesmos itens reordenados da melhor forma possível, e não com um gabarito externo comum às duas listas. Como esse ideal é

montado a partir da própria lista, o que a métrica de fato mede é o quão bem ordenada cada lista está em relação a si mesma, e não a qualidade dos seus itens frente aos da outra lista. O efeito disso é previsível: quando as notas dos itens são parecidas, quase qualquer ordem já se aproxima do ideal, e o nDCG sobe com facilidade. Por isso, aqui ele indica se cada lista está bem ordenada internamente, mas não permite apontar qual modelo entrega os itens mais relevantes. Essa comparação cabe às métricas que adotam um critério fixo de relevância, a Precisão em K e o MRR.

No experimento online, as médias de Likert obtidas ficaram abaixo do ponto médio da escala ($< 3,0$) em ambos os modelos avaliados. Como o limiar de relevância adotado é nota ≥ 3 , isso implica que a maioria das recomendações foi avaliada como não relevante pelos participantes. Embora o modelo Multiplicativo tenha superado o Baseline Semântico em cinco das seis métricas, a qualidade percebida, em termos absolutos, foi modesta.

Por fim, no experimento offline, a relevância foi definida pela coautoria: o autor-alvo aparecer como autor ou coautor do artigo retido. Esse critério avalia a capacidade do sistema de prever publicações relacionadas ao próprio pesquisador, o que difere parcialmente do problema motivador original, que trata da descoberta de trabalhos relevantes produzidos por terceiros. Essa distinção entre a métrica de avaliação e o objetivo enunciado no Capítulo 1 deve ser considerada na interpretação dos resultados.

No que diz respeito à validade do experimento online, três aspectos adicionais merecem atenção. Primeiro, a ordem de apresentação das duas listas não foi balanceada entre os participantes, o que pode ter introduzido efeitos de ordem ou de fadiga nas avaliações sequenciais. Em segundo lugar, o recrutamento foi realizado de forma voluntária por meio de um formulário, o que pode ter gerado viés de amostragem e limitado a generalização dos resultados a outras populações de pesquisadores. Por fim, embora o tempo de geração das recomendações tenha sido registrado (Seção 6.3.4), não foram coletadas métricas de latência sob carga concorrente nem isolado o impacto do cache Redis, o que impede uma caracterização completa do desempenho do sistema em produção.

Do ponto de vista técnico e metodológico, três limitações adicionais merecem destaque. A comparação semântica do sistema baseia-se em *word embeddings* estáticos gerados pelo modelo Word2Vec, uma abordagem consolidada, mas que não captura o contexto das palavras. A literatura recente sobre recomendações de artigos científicos já emprega amplamente modelos contextuais especializados, como SPECTER e SciBERT, que tendem a produzir representações mais precisas de textos acadêmicos. Além disso, o perfil do pesquisador é construído exclusivamente a partir de bigramas extraídos dos títulos de publicações recuperadas via ORCID, sem considerar resumos, redes de coautoria, citações recebidas ou a evolução temporal de seus interesses. Por fim, como os títulos são tipicamente curtos, a média par a par de similaridade entre todos os termos tende a diluir o sinal relevante, em vez de ponderá-lo. Essas limitações representam direções naturais para trabalhos futuros.

Do ponto de vista da conformidade e da fonte de dados, duas observações merecem registro. O sistema Recademy coleta e armazena dados pessoais dos pesquisadores participantes, incluindo nome, identificador ORCID e avaliações, em um banco de dados MongoDB. Embora o experimento tenha sido conduzido com participação voluntária e consentimento informado, o sistema não conta com uma política formal de privacidade

alinhada à Lei Geral de Proteção de Dados (LGPD), o que representa uma limitação para eventual disponibilização pública da plataforma. Adicionalmente, a classificação Qualis utilizada no fator de prestígio do veículo foi obtida a partir de um repositório mantido por terceiros (PUCRS), com base em edições anteriores do Qualis da CAPES. Considerando as reformulações recentes do sistema de avaliação de periódicos da CAPES, recomenda-se a atualização desta fonte para a edição vigente do Qualis Referência em trabalhos futuros.

6.4 ANÁLISE CONTEXTUAL COM A LITERATURA

Esta seção posiciona o Recademy em relação a sistemas da literatura com características metodológicas semelhantes. Dada a ausência de um benchmark unificado para recomendação de artigos científicos, a comparação é realizada de forma contextual, considerando estudos com configurações parcialmente compatíveis. Alguns trabalhos foram descartados por não reportarem os valores de K utilizados ou por adotarem critérios de avaliação muito distintos.

Tabela 6.4 Contextualização do Recademy frente a sistemas da literatura (domínios e protocolos distintos).

Algoritmo	Dataset/Contexto	MRR	P@K	nDCG	Observações
Baseline					
Random	News RecSys 2024	0,31	N/A	0,35	K não informado para MRR e P. K = 5 para nDCG.
Collab. Filtering (BPR)	MovieLens (ml-100k)	0,39	0,16	0,23	K=10.
CB (TF-IDF + Cosine)	Academic Collab.	N/A	0,78	0,89	K = 10 para as métricas disponíveis.
Content-Based (TF-IDF)	General Rec.	N/A	N/A	0,76	K não especificado.
Recademy (Multiplicativo)	DBLP-v10	0,371	0,197	0,446	K=3 para MRR e P. K=10 para nDCG.

A Tabela 6.4 ilustra os estudos que podem ser comparados à implementação do Recademy, tanto ao nível do algoritmo quanto nas configurações de experimento e nas métricas de avaliação. Nela estão dispostos o nome de cada algoritmo, o *dataset* ou contexto em que foi aplicado, os valores obtidos para cada uma das métricas em uma posição K e possíveis observações que facilitem a compreensão dos dados apresentados.

A comparação entre o modelo Recademy e os sistemas da literatura deve ser interpretada com cautela: os baselines selecionados foram originalmente avaliados em domínios distintos deste trabalho, como filmes (*MovieLens*), notícias (*News RecSys 2024*) e colaborações acadêmicas genéricas, e com valores de K e protocolos de avaliação heterogêneos, o que limita inferências diretas. Nesse contexto, o modelo Multiplicativo do Recademy apresentou desempenho superior ao Baseline Aleatório e à Filtragem Colaborativa (BPR),

com $MRR@3 = 0,371$ e $nDCG@10 = 0,446$. Em relação às abordagens baseadas em conteúdo aplicadas a repositórios acadêmicos, como CB (TF-IDF + Cosine), com $P@10 = 0,78$ e $nDCG = 0,89$, o modelo proposto apresenta valores inferiores, diferença atribuída, em parte, às diferenças de corpus, protocolo e conjunto de avaliação. Esses resultados indicam que o Recademy é funcional no contexto avaliado, embora comparações diretas com a literatura permaneçam limitadas pela heterogeneidade metodológica dos estudos disponíveis.

6.5 SUMÁRIO

Neste capítulo, a eficácia do sistema Recademy foi avaliada sob duas perspectivas complementares: um experimento *offline* controlado utilizando o *corpus* DBLP-v10 com 49 autores e um experimento *online* no formato de Teste A/B cego com 27 pesquisadores. Os dois experimentos produziram resultados divergentes, e a análise dessa divergência constitui uma das contribuições deste capítulo. No experimento *online*, o modelo multiplicativo superou o *Baseline Semântico* em todas as cinco dimensões do questionário de percepção e na maioria das métricas de ranqueamento, com diferenças estatisticamente significativas em $P@5$, $P@10$ e na média das notas atribuídas. No experimento *offline*, por outro lado, o mesmo modelo apresentou desempenho inferior ao *Baseline Semântico*, em razão do teto de *recall* imposto pela combinação multiplicativa com o fator Qualis, cuja cobertura alcança pouco mais da metade do conjunto de gabarito. As evidências sustentam, assim, uma hipótese mais precisa do que a inicialmente formulada: a incorporação de métricas acadêmicas como fatores moduladores melhora a relevância percebida quando o objetivo é selecionar itens de qualidade em um acervo amplo, mas implica perda de cobertura quando o alvo inclui publicações fora do escopo da métrica de prestígio adotada.

PROGRESSO E CRONOGRAMA

Este capítulo apresenta os passos percorridos durante a pesquisa até o estágio atual, incluindo as disciplinas cursadas, o estado de implementação e os resultados obtidos, bem como os próximos passos e o cronograma a ser seguido até a defesa da dissertação.

7.1 VIDA ACADÊMICA

Ao longo do mestrado, foram desenvolvidas atividades voltadas à formação teórica, ao desenvolvimento técnico do sistema e à condução dos experimentos de avaliação. A pesquisa concentrou-se no desenvolvimento de um sistema de recomendação de artigos científicos personalizado, que abrange desde a modelagem do perfil do pesquisador até a avaliação experimental, tanto online quanto offline. Entre disciplinas obrigatórias e optativas, foram cumpridas as cargas horárias necessárias à conclusão do curso.

7.1.1 Disciplinas Cursadas

- **PGCOMP/IC0028 — Seminários Científicos:** Disciplina obrigatória na qual foram apresentados trabalhos desenvolvidos pelos diferentes grupos de pesquisa do programa de pós-graduação. A disciplina proporcionou uma visão ampla das linhas de pesquisa em Ciência da Computação e contribuiu para o desenvolvimento da capacidade de síntese e de comunicação científica. Esta disciplina foi ministrada pelo professor Manoel Gomes de Mendonça Neto.
- **PGCOMP/IC0029 — Fundamentos de Pesquisa em Ciência da Computação I:** Disciplina obrigatória voltada ao processo de pesquisa científica em computação. Abordou temas como metodologia científica, revisão sistemática da literatura, escrita acadêmica e ética em pesquisa, fornecendo a base metodológica para a condução desta dissertação. O responsável pela disciplina foi o professor Frederico Araújo Durão.
- **PGCOMP/IC0004 — Algoritmos e Grafos:** Disciplina obrigatória que abordou os fundamentos dos algoritmos clássicos, noções de complexidade, algoritmos

gulosos, programação dinâmica, recursividade e técnicas de divisão e conquista. Os conhecimentos adquiridos contribuíram para a análise de eficiência dos componentes do sistema proposto. O responsável por essa disciplina foi o professor George Marconi de Araújo Lima.

- **PGCOMP/IC0007 — Tópicos em Banco de Dados I:** Disciplina optativa que, apesar do título, aprofundou conceitos de Processamento de Linguagem Natural (PLN), incluindo técnicas de representação vetorial de palavras e modelos de *embedding*. Os conhecimentos adquiridos foram diretamente aplicados no componente de similaridade semântica do sistema Recademy, responsável por calcular a proximidade entre o perfil do pesquisador e os artigos candidatos. A responsável por essa disciplina foi a professora Daniela Barreiro Claro.
- **PGCOMP/IC0045 — Tópicos em Sistemas de Informação e Web I:** Disciplina optativa com foco em arquitetura de sistemas web, integração de serviços e boas práticas de desenvolvimento de software. Como projeto principal, foi desenvolvido um sistema de acompanhamento do desempenho acadêmico voltado à administração do PGCOMP/IC, que permite o monitoramento de indicadores relevantes dos docentes para a avaliação da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES). O responsável pela disciplina foi o professor Frederico Araújo Durão.
- **PGCOMP/IC0036 — Inteligência Artificial:** Disciplina optativa que abordou os fundamentos e as técnicas de Inteligência Artificial, incluindo representação do conhecimento, busca heurística e aprendizado de máquina. Os conceitos estudados aprofundaram a compreensão dos modelos de representação vetorial empregados no componente de similaridade semântica do sistema. A responsável por essa disciplina foi a professora Tatiane Nogueira Rios.
- **MATA31 — Pesquisa Orientada:** Atividade de acompanhamento contínuo da pesquisa junto ao orientador, cursada ao longo de múltiplos semestres. Permitiu o desenvolvimento iterativo da proposta, o refinamento da metodologia e a elaboração dos capítulos da dissertação.
- **MATA32 — Estágio Docente Orientado:** Disciplina na qual foram apoiadas as atividades da disciplina de graduação *Introdução à Lógica de Programação*. A atuação consistiu no acompanhamento dos discentes no desenvolvimento das atividades práticas submetidas ao sistema *Judge*, uma plataforma de avaliação automática de código que testa e valida as soluções enviadas pelos estudantes. A experiência contribuiu para o desenvolvimento de habilidades de comunicação, didática e de acompanhamento pedagógico. O responsável pela disciplina foi o professor Cláudio Nogueira Sant'Anna.

7.2 CRONOGRAMA

O sistema proposto encontra-se completamente implementado e os experimentos de avaliação foram integralmente conduzidos. Os resultados foram obtidos e analisados, estando documentados nos Capítulos 5 e 6 desta dissertação. As atividades pendentes concentram-se na incorporação das contribuições da banca de qualificação, na redação de artigo científico e na defesa da dissertação.

1. **A01 — Cursar disciplinas obrigatórias:** Cursar e obter aprovação nas disciplinas obrigatórias do mestrado (Seminários Científicos, Fundamentos de Pesquisa e Algoritmos e Grafos). *Concluída.*
2. **A02 — Cursar disciplinas optativas:** Cursar disciplinas complementares à pesquisa (Banco de Dados I, Sistemas de Informação e Web I, Inteligência Artificial). *Em andamento.*
3. **A03 — Definição do tema da pesquisa:** Identificação da linha de pesquisa em sistemas de recomendação de artigos científicos e definição do escopo do sistema Recademy. *Concluída.*
4. **A04 — Levantamento de trabalhos relacionados:** Pesquisa e análise de trabalhos nas áreas de Sistemas de Recomendação, Processamento de Linguagem Natural e Recuperação de Informação. *Concluída.*
5. **A05 — Desenvolvimento do sistema Recademy:** Implementação da API REST, do motor de recomendação e da interface web de avaliação. *Concluída.*
6. **A06 — Experimento online (Teste A/B):** Condução do experimento com 27 pesquisadores reais utilizando a interface web de avaliação. *Concluída.*
7. **A07 — Experimento offline (DBLP-v10):** Condução do experimento controlado com 49 autores do corpus DBLP-v10. *Concluída.*
8. **A08 — Estágio Docente Orientado:** Participação como monitor em disciplina de graduação, apoiando discentes em atividades práticas. *Concluída.*
9. **A09 — Escrita da qualificação:** Elaboração do texto a ser submetido à banca de qualificação. *Concluída.*
10. **A10 — Qualificação do mestrado:** Apresentação da pesquisa à banca de qualificação. *A realizar.*
11. **A11 — Incorporação das críticas recebidas:** Revisão e aprimoramento da dissertação com base nas contribuições da banca de qualificação. *A realizar.*
12. **A12 — Escrita de artigo científico:** Elaboração de artigo científico com base nos resultados experimentais obtidos, com foco na publicação em evento ou em periódico qualificado. *A realizar.*

13. **A13 — Adaptação para a dissertação final:** Consolidação do texto revisado para a versão definitiva da dissertação. *A realizar.*
14. **A14 — Defesa da dissertação:** Apresentação final da dissertação de mestrado. *A realizar.*

O cronograma das atividades realizadas desde o ingresso no mestrado, bem como as a serem concluídas após a qualificação, está detalhado na lista acima.

7.3 SUMÁRIO

Este capítulo apresentou um resumo das atividades realizadas durante o mestrado, com foco no desenvolvimento de um sistema de recomendação personalizado de artigos científicos. Foram cursadas disciplinas obrigatórias e optativas que embasaram o desenvolvimento técnico e a fundamentação científica da pesquisa. O cronograma evidencia que os experimentos de avaliação foram integralmente conduzidos e que as atividades remanescentes concentram-se na incorporação das contribuições da banca, na publicação de artigos e na defesa da dissertação.

REFERÊNCIAS BIBLIOGRÁFICAS

ADOMAVICIUS, G.; TUZHILIN; ALEXANDER. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, Institute of Electrical and Electronics Engineers (IEEE), v. 17, n. 6, p. 734–749, jun 2005.

AFSAR, M. M.; CRUMP, T.; FAR, B. An exploration on-demand article recommender system for cancer patients information provisioning. *The International FLAIRS Conference Proceedings*, v. 34, Apr. 2021. Disponível em: <<https://journals.flvc.org/FLAIRS/article/view/128339>>.

ALHIJAWI, B.; KILANI, Y. A collaborative filtering recommender system using genetic algorithm. *Information Processing & Management*, v. 57, n. 6, p. 102310, 2020. ISSN 0306-4573. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0306457320308050>>.

AMINI, B.; IBRAHIM, R.; OTHMAN, M. S. Discovering the impact of knowledge in recommender systems: A comparative study. *CoRR*, abs/1109.0166, 2011. Disponível em: <<http://arxiv.org/abs/1109.0166>>.

BROUWER, W.; HOLLENBACH, M. Search engine optimization for scientific publications: How one can find your needle in the haystack. *United European Gastroenterology Journal*, v. 10, p. 906 – 908, 2022.

BURKE, R. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, Kluwer Academic Publishers, Hingham, MA, USA, v. 12, n. 4, p. 331–370, nov. 2002. ISSN 0924-1868. Disponível em: <<http://dx.doi.org/10.1023/A:1021240730564>>.

BURKE, R. Hybrid web recommender systems. In: BRUSILOVSKY, P.; KOBSA, A.; NEJDL, W. (Ed.). *The adaptive web: methods and strategies of web personalization*. Berlin, Heidelberg: Springer-Verlag, 2007. p. 377–408. ISBN 978-3-540-72078-2. Disponível em: <<http://dl.acm.org/citation.cfm?id=1768197.1768211>>.

CARVALHO, D. et al. Fair: A framework for analyses and evaluations on recommender systems. In: *Computational Science and Its Applications – ICCSA 2018*. Cham: Springer International Publishing, 2018. p. 383–397. ISBN 978-3-319-95168-3.

CAZELLA, S. C. et al. Recomendação de objetos de aprendizagem empregando filtragem colaborativa e competências. In: *XX Simpósio Brasileiro de Informática na Educação*. [s.n.], 2009. Disponível em: <<https://www.semanticscholar.org/paper/Recomenda%>

C3%A7%C3%A3o-de-Objetos-de-Aprendizagem-Empregando-Cazella-Reategui/ca85252192a52882e10426bb7778457d6e5f3ab3>.

CHEN, J. et al. Collaborative filtering recommendation algorithm based on user correlation and evolutionary clustering. *Complex Intell. Syst.*, Springer Science and Business Media LLC, v. 6, n. 1, p. 147–156, abr. 2020.

CLAYPOOL, M. et al. Combining content-based and collaborative filters in an online newspaper. In: *Proceedings of the ACM SIGIR '99 Workshop on Recommender Systems: Algorithms and Evaluation*. Berkeley, California: ACM, 1999.

COSTA, E.; AGUIAR, J.; MAGALHÃES, J. Sistemas de recomendação de recursos educacionais: Conceitos, técnicas e aplicações. In: _____. [s.n.], 2013. p. 57–78. ISBN 9788576692836. Disponível em: <https://www.researchgate.net/publication/275345110_Sistemas_de_Recomendacao_de_Recursos_Educacionais_Conceitos_Tecnicas_e_Aplicacoes>.

DECLERCQ, J.; POPPEL, L. van. Coding metaphors in interaction: A study protocol and reflection on validity and reliability challenges. *International Journal of Qualitative Methods*, v. 22, 2023. Disponível em: <<https://doi.org/10.1177/16094069231164608>>.

DNC, E. *Implementando um sistema de recomendação de cursos: análise e aplicação*. 2024. <<https://www.escoladnc.com.br/blog/implementando-um-sistema-de-recomendacao-de-cursos-analise-e-aplicacao/>>.

ELSEVIER; SCIENCE, S. A. *Trust in Research Report*. 2019. Disponível em: <https://web.archive.org/web/20230223060917/https://www.elsevier.com/__data/assets/pdf_file/0011/908435/Trust_evidence_report_summary_Final.pdf>.

FALCADE, L.; FALCADE, A.; ABEGG, I. Linha do tempo das políticas públicas voltadas para a informática educativa. *SciELO Preprints*, set. 2024. Disponível em: <<https://preprints.scielo.org/index.php/scielo/preprint/view/10081>>.

GALVÃO, M. C. B.; RICARTE, I. L. M. Revisão sistemática da literatura: Conceituação, produção e publicação. *Logeion: Filosofia da Informação*, v. 6, n. 1, p. 57–73, set. 2019. Disponível em: <<https://revista.ibict.br/fiinf/article/view/4835>>.

GARCÍA, I.; BELLOGÍN, A. Towards an open, collaborative rest api for recommender systems. In: *Proceedings of the 12th ACM Conference on Recommender Systems*. New York, NY, USA: Association for Computing Machinery, 2018. (RecSys '18), p. 504–505. ISBN 9781450359016. Disponível em: <<https://doi.org/10.1145/3240323.3241615>>.

GHANNADRAD, A. et al. Recommender systems for science: A basic taxonomy. In: *Italian Research Conference on Digital Library Management Systems*. [s.n.], 2022. Disponível em: <<https://api.semanticscholar.org/CorpusID:251008452>>.

GOLDBERG, D. et al. Using collaborative filtering to weave an information tapestry. *Commun. ACM*, ACM, New York, NY, USA, v. 35, n. 12, p. 61–70, dez. 1992. ISSN 0001-0782. Disponível em: <<http://doi.acm.org/10.1145/138859.138867>>.

HANYURWIMFURA, D. et al. An effective academic research papers recommendation for non-profiled users. *International Journal of Hybrid Information Technology*, v. 8, p. 255–272, 03 2015.

HERLOCKER, J. L. et al. Evaluating collaborative filtering recommender systems. *ACM Trans. Inf. Syst.*, ACM, New York, NY, USA, v. 22, n. 1, p. 5–53, jan. 2004. ISSN 1046-8188. Disponível em: <<http://doi.acm.org/10.1145/963770.963772>>.

HIMEUR, Y. et al. Latest trends of security and privacy in recommender systems: A comprehensive review and future perspectives. *Computers & Security*, v. 118, p. 102746, 2022. ISSN 0167-4048. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167404822001419>>.

ISINKAYE, F.; FOLAJIMI, Y.; OJOKOH, B. Recommendation systems: Principles, methods and evaluation. *Egyptian Informatics Journal*, Elsevier BV, v. 16, n. 3, p. 261–273, nov 2015. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S1110866515000341>>.

JU, C. M. et al. *Revisiting Self-attention for Cross-domain Sequential Recommendation*. 2025. Disponível em: <<https://arxiv.org/abs/2505.21811>>.

KENDE, M. et al. Global connectivity report 2022. chapter 1. universal and meaningful connectivity: The new imperative. *SYNCHROINFO JOURNAL*, Media-Publisher, v. 8, n. 2, p. 35–45, 2022.

KIM, J. K.; CHOI, I.-Y.; LI, Q. Customer satisfaction of recommender system: Examining accuracy and diversity in several types of recommendation approaches. *Sustainability*, v. 13, p. 6165, May 2021. Disponível em: <<https://www.researchgate.net/publication/351994770>>.

KREUTZ, C.; SCHENKEL, R. Scientific paper recommendation systems: a literature review of recent publications. *International Journal on Digital Libraries*, Springer, p. 335–369, 2022. Disponível em: <<https://doi.org/10.1007/s00799-022-00339-w>>.

LAMPROPOULOS, G. Recommender systems in education: A literature review and bibliometric analysis. *Adv. Mobile Learn. Educ. Res.*, Syncsci Publishing Pte., Ltd., v. 3, n. 2, p. 829–850, set. 2023.

LI, Y. et al. Enhancing systematic literature reviews with generative artificial intelligence: development, applications, and performance evaluation. *J. Am. Med. Inform. Assoc.*, v. 32, n. 4, p. 616–625, abr. 2025.

LOPS, P.; GEMMIS, M. de; SEMERARO, G. Content-based recommender systems: State of the art and trends. In: RICCI, F. et al. (Ed.). *Recommender Systems Handbook*. Springer US, 2011. p. 73–105. ISBN 978-0-387-85819-7. Disponível em: <http://dx.doi.org/10.1007/978-0-387-85820-3_3>.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. New York, NY, USA: Cambridge University Press, 2008. ISBN 0521865719, 9780521865715.

MARUYAMA, M. et al. Hybrid recommender system for educational resources to the smart university campus domain. In: INSTICC. *Proceedings of the 15th International Conference on Computer Supported Education - Volume 1: CSEDU*. [S.l.]: SciTePress, 2023. p. 47–56. ISBN 978-989-758-641-5. ISSN 2184-5026.

MLADENIC, D. Text-learning and related intelligent agents: A survey. *IEEE Intelligent Systems*, IEEE Educational Activities Department, Piscataway, NJ, USA, v. 14, n. 4, p. 44–54, jul. 1999. ISSN 1541-1672. Disponível em: <<http://dx.doi.org/10.1109/5254.784084>>.

NOBLE, H.; SMITH, J. Issues of validity and reliability in qualitative research. *Evidence-Based Nursing*, Royal College of Nursing, Apr 2015. Disponível em: <<https://ebn.bmj.com/content/18/2/34>>.

PARRA, D.; SAHEBI, S. Recommender systems: Sources of knowledge and evaluation metrics. In: VELÁSQUEZ, J. D.; PALADE, V.; JAIN, L. C. (Ed.). *Advanced Techniques in Web Intelligence-2*. Springer Berlin Heidelberg, 2013, (Studies in Computational Intelligence, v. 452). p. 149–175. ISBN 978-3-642-33325-5. Disponível em: <http://dx.doi.org/10.1007/978-3-642-33326-2_7>.

PFEFFER, J. et al. Just another day on twitter: A complete 24 hours of twitter data. In: *International Conference on Web and Social Media*. [s.n.], 2023. Disponível em: <<https://api.semanticscholar.org/CorpusID:256358700>>.

PINEDO, I.; LARRAÑAGA, M.; ARRUARTE, A. *Recent Advances and Trends in Research Paper Recommender Systems: A Comprehensive Survey*. 2025. Disponível em: <<https://arxiv.org/abs/2508.08828>>.

RESNICK, P.; VARIAN, H. R. Recommender systems. *Commun. ACM*, ACM, New York, NY, USA, v. 40, n. 3, p. 56–58, mar. 1997. ISSN 0001-0782. Disponível em: <<http://doi.acm.org/10.1145/245108.245121>>.

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender systems: Techniques, applications, and challenges. In: _____. *Recommender Systems Handbook*. Springer US, 2022. p. 1–35. ISBN 978-1-0716-2197-4. Disponível em: <https://doi.org/10.1007/978-1-0716-2197-4_1>.

RICCI, F. et al. (Ed.). *Recommender Systems Handbook*. Springer, 2011. ISBN 978-0-387-85819-7. Disponível em: <<http://www.springerlink.com/content/978-0-387-85819-7>>.

ROY, D.; DUTTA, M. A systematic review and research perspective on recommender systems. *J. Big Data*, Springer Science and Business Media LLC, v. 9, n. 1, dez. 2022.

SALTON, G. (Ed.). *Automatic Text Processing*. Boston, MA, USA: Addison-Wesley Longman Publishing Co., Inc., 1988. ISBN 0-2:1-1227-8.

SARWAR, B. et al. Item-based collaborative filtering recommendation algorithms. In: *Proceedings of the tenth international conference on World Wide Web - WWW '01*. ACM Press, 2001. (WWW '01), p. 285–295. ISBN 1-58113-348-0. Disponível em: <<http://doi.acm.org/10.1145/371920.372071>>.

SHANI, G.; GUNAWARDANA, A. *Evaluating Recommender Systems*. [S.l.], 2009. Disponível em: <<http://research.microsoft.com/apps/pubs/default.aspx?id=115396>>.

SILVA, F. L. da et al. A systematic literature review on educational recommender systems for teaching and learning: research trends, limitations and opportunities. *Education and Information Technologies*, v. 28, n. 3, p. 3289–3328, Mar 2023. ISSN 1573-7608. Disponível em: <<https://doi.org/10.1007/s10639-022-11341-9>>.

SNYDER, H. Literature review as a research methodology: An overview and guidelines. *Journal of Business Research*, v. 104, p. 333–339, 2019. ISSN 0148-2963. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0148296319304564>>.

STERLING, J. A.; MONTEMORE, M. M. Combining citation network information and text similarity for research article recommender systems. *IEEE Access*, v. 10, p. 16–23, 2022. Disponível em: <<https://ieeexplore.ieee.org/document/9661321>>.

WANG, D. et al. A content-based recommender system for computer science publications. *Knowledge-Based Systems*, v. 157, p. 1–9, 2018. ISSN 0950-7051.

WEI, X. et al. Personalized online learning resource recommendation based on artificial intelligence and educational psychology. *Frontiers in Psychology*, v. 12, 2021. ISSN 1664-1078. Disponível em: <<https://www.frontiersin.org/journals/psychology/articles/10.3389/fpsyg.2021.767837>>.

YAZDI, H. A.; MAHDAVI, S. J. S.; YAZDI, H. A. Dynamic educational recommender system based on improved lstm neural network. *Scientific Reports*, Nature Publishing Group, v. 14, p. 54729, 2024. Disponível em: <<https://www.nature.com/articles/s41598-024-54729-y>>.

YU, J. *Enhancing recommender systems with self-supervised learning*. Tese (Doutorado) — School of Information Technology and Electrical Engineering - The University of Queensland, 2023. Disponível em: <<https://doi.org/10.14264/9b4b38b>>.

ZHANG, C. et al. *Multifaceted User Modeling in Recommendation: A Federated Foundation Models Approach*. 2024. Disponível em: <<https://arxiv.org/abs/2412.16969>>.

ZHANG, S. et al. Deep learning based recommender system: A survey and new perspectives. *ACM Computing Surveys*, Association for Computing Machinery (ACM), v. 52, n. 1, p. 1–38, fev. 2019. ISSN 1557-7341. Disponível em: <<http://dx.doi.org/10.1145/3285029>>.

ZHAO, X. et al. *Embedding in Recommender Systems: A Survey*. 2023.

ZHENG, Y. *ITM-Rec: An Open Data Set for Educational Recommender Systems*. 2023. Disponível em: <<https://arxiv.org/abs/2303.10230>>.