



Universidade Federal da Bahia
Departamento de Ciência da Computação
Mestrado em Ciência da Computação

Recademy - Um Modelo Multifatorial Para Recomendação Personalizada de Artigos Científicos


Orientando: Lucas França Freitas
Orientador: Frederico Araujo Durão

Agenda

- Introdução
- Referencial Teórico
- Trabalhos Relacionados
- Proposta
- Avaliação Experimental
- Conclusão

Sistemas de Recomendação

- Auxiliam na filtragem e personalização do conteúdo, aprimorando satisfação e engajamento dos usuários, além de proporcionar aumento em conversão nas plataformas [KIM, CHOI, LEE; 2021].



Publicações Open Science

- Volume crescente de publicações em repositórios abertos [BROUWER, HOLLENBACH; 2022].
- Peso crescente da qualidade do veículo [FIRE; GUESTIN; 2019].

Contextualização


- Sobrecarga de informação na pesquisa científica [LI *et al.*; 2025]
- Tempo gasto na busca por artigos relevantes
- Integração entre sistemas
- Validação e confiabilidade dos trabalhos
[DECLERCQ, VAN POPPEL; 2023]



Problema

- Tempo excessivo na busca por manuscritos relevantes
- Distração e ruptura de foco
- Sobrecarga e exaustão
- Informações desatualizadas ou enviesadas
- Falta de personalização

Problema



Fonte: Elsevier

Objetivo geral

Desenvolver um sistema multifatorial de recomendação de artigos científicos que combine a relevância para o perfil do pesquisador à importância e ao impacto de cada artigo (atualidade, citações e prestígio do veículo), a partir de fontes abertas na Web.

Objetivos específicos

- **OE1:** Propor uma arquitetura *Web* para desenvolvimento de sistema de recuperação de manuscritos
- **OE2:** Modelar o perfil de usuário a partir do conteúdo de seus trabalhos publicados
- **OE3:** Desenvolver um algoritmo de recomendação baseado no perfil do usuário
- **OE4:** Avaliar as recomendações geradas

Referencial Teórico


- Sistemas de Recomendação
- Filtragem Colaborativa
- Filtragem Baseada em Conteúdo
- Publicação Científica

Trabalhos relacionados (destaques)

- **Wang *et al* (2018)** - Sistema de recomendação de publicações científicas
- **Kreutz e Schenkel (2022)** – Revisão sistemática de SRs para publicações
- **Yu (2023)** – Desenvolvimento de SRs com aprendizado não-supervisionado
- **Sterling e Montemore (2022)** – Recomendação por redes de citações e similaridade textual

Filtragem Colaborativa

- Uma das técnicas mais populares em Sistemas de Recomendação, e a mais amplamente implementada, consiste em recomendar itens ao usuário ativo a partir do gosto de outros usuários no passado [RICCI *et al.*; 2011].




Processamento de Linguagem Natural

- Conjunto de técnicas para representar e comparar textos de forma computável, usadas no Recademy para medir a proximidade semântica entre o perfil do pesquisador e os artigos.

Técnicas comunmente utilizadas:

- Tokenização
- Lematização
- Extração de palavras-chave
- Word embeddings - Word2Vec [ZHAO et al., 2023]



Recomendação Baseada em Conteúdo

- Metadados e conteúdo descritivo são comparados por funções de

$$\text{simCosine}(u, v) = \frac{\sum_{i \in I_{uv}} r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i \in I_{uv}} r_{u,i}^2} \sqrt{\sum_{i \in I_{uv}} r_{v,i}^2}}$$


- $\wedge$
- No Recademy, corresponde ao componente $\text{Sem}(p, \tau)$, aplicado aos vetores Word2Vec.

Publicação Científica

- O que torna um artigo relevante
 - Citações: impacto do artigo
 - Qualis (CAPES): prestígio e qualidade do veículo de publicação
 - Atualidade: proximidade com o estado da arte da área
- Bases públicas e dados abertos
 - OpenAlex: metadados e contagem de citações
 - DBLP: indexação de publicações em Ciência da Computação
 - ORCID: identificação e histórico do pesquisador

RECADEMY - UM MODELO MULTIFATORIAL PARA RECOMENDAÇÃO PERSONALIZADA DE ARTIGOS CIENTÍFICOS

Arquitetura do Sistema



Modelo de usuário

- $\theta(u)$ = vetor de pesos de palavras-chave que representa o usuário $u \in U$
- Fontes (histórico acadêmico via ORCID):
 - Publicações
 - Formação acadêmica
 - Revisões
 - Atuação profissional
- As palavras-chave extraídas dessas fontes formam o vetor $\theta(u)$, comparado aos artigos pela similaridade de cosseno (componente $\text{Sem}(p, \tau)$).

Modelo de Recomendação

Input: $id \in \text{String}$ (identificador do usuário)
Output: $\mathcal{P}$ (lista de publicações)

```
1  $U \leftarrow \text{usuário}(id)$ ;  
2  $\mathcal{S} \leftarrow \emptyset$ ;  
3  $\mathcal{P} \leftarrow \emptyset$ ;  
4 foreach  $s \in U.\text{fontes}$  do  
5   if  $s_{\text{serviço}} = \text{ORCID}$  then  
6      $\mathcal{S} \leftarrow \text{resumo\_usuário}(s_{\text{url}})$ ;  
7 if  $\mathcal{S} \neq \emptyset$  then  
8   foreach  $\tau \in \mathcal{S}$  do  
9      $\mathcal{T}(\tau) \leftarrow \text{construir\_consulta}(\tau)$ ;  
10     $\mathcal{P}_{\tau} \leftarrow \emptyset$ ;  
11    foreach  $q \in \mathcal{T}(\tau)$  do  
12       $\mathcal{P}_q \leftarrow \text{buscar\_publicações}(q)$ ;  
13       $\mathcal{P}_{\tau} \leftarrow \mathcal{P}_{\tau} \cup \mathcal{P}_q$ ;  
14     $\mathcal{P}_{\tau} \leftarrow \{p \in \mathcal{P}_{\tau} : \text{publicações\_válidas}(p)\}$ ;  
15     $p_{\text{melhor}} \leftarrow \emptyset$ ;  
16    if  $\mathcal{P}_{\tau} \neq \emptyset$  then  
17       $p_{\text{melhor}} \leftarrow \text{selecionar\_melhor}(\mathcal{P}_{\tau}, \tau, U)$ ;  
18    if  $p_{\text{melhor}} \neq \emptyset$  then  
19       $\mathcal{P} \leftarrow \mathcal{P} \cup \{p_{\text{melhor}}\}$ ;  
20    if  $|\mathcal{P}| = 10$  then  
21      return  $\mathcal{P}$ ;  
22 return  $\mathcal{P}$ ;
```

Equação de Pontuação

- Combinação multiplicativa de 4 componentes normalizados em $[0, 1]$
- Componentes
 - Sem - Similaridade semântica (Word2Vec)
 - Ano - Ano de publicação (decaimento logarítmico)
 - Cit - Citações por ano (normalização Min-Max)
 - Rel - Prestígio do veículo (Qualis)

$$Score = Sem(p, r) * Ano(p) * Cit(p) * Rel(p)$$

Exemplo de retorno da integração OpenAlex

```
{
  "rank": 1,
  "title": "What's trending in difference-in-differences? A synthesis of the recent econometrics literature",
  "year": 2023,
  "venue": "Journal of Econometrics",
  "authors": [
    "Jonathan Roth",
    "Pedro H. C. SantosAnna",
    "Alyssa Bilinski",
    "John Poe"
  ],
  "n_citation": 1623,
  "abstract": "",
  "doi": "https://doi.org/10.1016/j.jeconom.2023.03.008",
  "scores": {
    "score_total": 0.0078,
    "score_sem": 0.2193,
    "score_rec": 0.2263,
    "score_cit": 0.2092,
    "qua_term": 0.75,
    "qua_raw": 0.75
  },
  "avaliacao_usuario": null,
  "comentario": null
}
```

Avaliação Experimental

- Avaliação online com usuários
- Avaliação offline com dataset públicos

Experimento Online

Interface Web de Avaliação

Avaliação do Sistema Recademy

Com base no título da sua pesquisa, o Recademy selecionou duas listas (Lista 1 e Lista 2) com 10 artigos científicos cada para você avaliar.
Para cada artigo, indique o quanto ele é relevante para o seu tema usando a escala de 1 (Totalmente Irrelevante) a 5 (Muito Relevante).

⌚ Tempo estimado: 10 a 15 minutos. Obrigado pela participação!

Selecione seu nome abaixo para começar:

Stéfane Oliveira [CONCLUÍDO]

Acessar

Seu Tema Base:

Fuzzy for hyperparameter adaptation in Federated Learning for the Internet of Things

Avalie os artigos abaixo em relação ao tema base (1 = Totalmente Irrelevante, 5 = Muito Relevante).

Lista 1

1. Federated learning for medical image analysis: A survey

Autores: Hao Guan, Pew-Thian Yap, Andrea Bozoki, Mingxia Liu | **Ano:** 2024 | **Local:** Pattern Recognition

DOI: <https://doi.org/10.1016/j.patrec.2024.110424>

Qual a relevância deste artigo para o seu tema?

1 2 3 4 5

Comentário opcional sobre por que deu essa nota...

2. Federated Learning With Non-IID Data: A Survey

Autores: Zili Lu, Heng Pan, Yueyue Dai, Xueming Si, Yan Zhang | **Ano:** 2024 | **Local:** IEEE Internet of Things Journal

DOI: <https://doi.org/10.1109/iot.2024.33776548>

🔍 Olhar resumo

Federated learning (FL) is an efficient decentralized machine learning methodology for processing non-independent and identically distributed (non-IID) data due to geographical and temporal distribution differences. Non-IID data generally indicates substantial disparities in data distribution and features among clients. This assumption is completely different from the conventional assumption of independent and identically distributed (IID) data in which all clients' data originates from the same distribution. There are many factors that affect the features of non-IID data, such as user preferences, data collection methods, and client characteristics. The factors of data distribution, category proportions, and feature representation also affect the statistical properties of non-IID data. This paper conducts an in-depth exploration of FL with the consideration of diverse features and statistical properties of non-IID data. Specifically, we first discuss the impact of non-IID data on communication efficiency, model convergence, and FL accuracy. The presence of non-IID data leads to increased communication overhead, imbalanced class distribution, and uneven local model updates. All of these affect FL convergence and performance. Then, we present the latest advanced techniques, such as data partitioning/sharing, client selection, differential privacy, and secure aggregation [1], which are used to address the challenges posed by non-IID data in terms of communication efficiency and

Qual a relevância deste artigo para o seu tema?

1 2 3 4 5

Interface Web de Avaliação

- Recomendações exibidas em lista para avaliação
- Cada recomendação exibe os dados do artigo: título, autores, ano, veículo, DOI e resumo
- Avaliação dos usuários (1–5) por artigo
- Comentário opcional por recomendação
- Questionário de percepção subjetiva (5 dimensões)

Interface Web de Avaliação

1. Transfer Learning in Deep Reinforcement Learning: A Survey

Autores: Zhuangdi Zhu, Kaixiang Lin, Anil K. Jain, Jiayu Zhou | **Ano:** 2023 | **Local:** IEEE Transactions on Pattern Analysis and Machine Intelligence

DOI: <https://doi.org/10.1109/tpami.2023.3292075>

▲ Ocultar resumo

Reinforcement learning is a learning paradigm for solving sequential decision-making problems. Recent years have witnessed remarkable progress in reinforcement learning upon the fast development of deep neural networks. Along with the promising prospects of reinforcement learning in numerous domains such as robotics and game-playing, transfer learning has arisen to tackle various challenges faced by reinforcement learning, by transferring knowledge from external expertise to facilitate the efficiency and effectiveness of the learning process. In this survey, we systematically investigate the recent progress of transfer learning approaches in the context of deep reinforcement learning. Specifically, we provide a framework for categorizing the state-of-the-art transfer learning approaches, under which we analyze their goals, methodologies, compatible reinforcement learning backbones, and practical applications. We also draw connections between transfer learning and other relevant topics from the reinforcement learning perspective and explore their potential challenges that await future research progress.

Qual a relevância deste artigo para o seu tema?

1 2 3 4 5

Comentário opcional sobre por que deu essa nota...

Questionário sobre a Lista 1

Avalie o conjunto de recomendações da Lista 1 (1 = Discordo totalmente, 5 = Concordo totalmente).

1. Relevância

Os artigos recomendados são relevantes para meus interesses de pesquisa ou para o tema investigado.

1 2 3 4 5

2. Diversidade

As recomendações abordaram diferentes perspectivas, subáreas ou abordagens dentro do meu tema de pesquisa.

1 2 3 4 5

3. Precisão

As recomendações correspondem com precisão ao assunto ou contexto de busca informado.

1 2 3 4 5

4. Atualidade

Os artigos recomendados refletem publicações recentes ou abordagens atualizadas sobre o tema.

1 2 3 4 5

5. Surpresa (Serendipidade)

As recomendações apresentaram artigos inesperados, mas que ainda assim se mostraram úteis ou potencialmente valiosos para minha pesquisa.

1 2 3 4 5

Metodologia

- Objetivo: Avaliar a precisão do modelo de scoring multiplicativo
- Teste A/B cego com duas listas:
 - Lista 1: Modelo Multiplicativo (Sem * Ano * Cit * Rel)
 - Lista 2: Baseline Semântico (Apenas similaridade)
- Relevância: artigo com nota ≥ 3 conta como relevante
- As duas listas partem da mesma entrada e dos mesmos candidatos.

Conjunto de Dados

Experimento Online (Teste A/B)

- 27 voluntários
- Entrada: título da linha de pesquisa (planilha);
- Artigos recuperados via OpenAlex

Métricas de Avaliação

- MRR – Mean Reciprocal Rank
- nDCG - Normalized Discounted Cumulative Gain
- MAP - Mean Average Precision
- Precisão (P@K)
- Avaliações dos usuários (1-5)

Métricas de Validação

Precisão $\text{precision} = \frac{|g \cap r|}{|r|}$

- Dos itens recomendados, a fração que de fato é relevante (P@5, P@10).

MRR $\text{MRR} = \frac{1}{m} \sum_{i=1}^m \frac{1}{\text{rank}_i}$

- Mean Reciprocal Rank mede em que posição aparece o primeiro item relevante

nDCG $\text{DCG} = \sum_{i=1}^n \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}$


- Normalized Discounted Cumulative Gain premia a lista que coloca os itens mais relevantes no topo, considerando relevância e posição

MAP $\text{MAP} = \frac{1}{m} \sum_{i=1}^m \frac{1}{|g_i|} \sum_{j=1}^{|g_i|} P@k_{ij}$

- Mean Average Precision é a precisão média ao longo da lista, medida em cada posição onde aparece um item relevante.


MRR e Precisão

Comparativo de Métricas do Teste A/B (n = 27)




Multiplicativo vence em MRR, MAP, P@5 e P@10; empate técnico em nDCG

nDCG




nDCG quase empatado: mede a ordenação interna de cada lista, não qual modelo entrega os melhores itens.

Avaliação dos Usuários



Multiplicativo superior em todas as 5 dimensões. Destaque: Atualidade

Teste de Performance



Custo de tempo equivalente: o Multiplicativo não adiciona overhead relevante, e é ligeiramente mais rápido.

Experimento Offline


Conjunto de Dados

- 49 autores selecionados (> 30 publicações)
- Hold-Out com Candidate Injection: 20 conjuntos de treino + 10 de gabarito
- Janela temporal utilizada: 2013 ~ 2017
- Limitação: no score multiplicativo, veículos sem prestígio classificado zeram o resultado (teto de recall)

Metodologia

- Objetivo: Validar o modelo em ambiente controlado
- 4 modelos comparados:
 - Baseline Aleatório
 - Baseline Semântico
 - Multiplicativo ($Sem * Ano * Cit * Rel$)
 - Aditivo ($Sem + Ano + Cit + Rel$)
- Gabarito: artigos de autoria ou coautoria do próprio pesquisador

Comparação de *baselines*



Resultado offline

- 225 dos 490 gabaritos (45,9%) ficaram com o score zerado
- Similaridade pura foi premiada: Gabarito com papers do próprio autor
- Entre os modelos de quatro fatores, o multiplicativo supera o aditivo em todas as métricas

Conclusão

Contribuições

- Sistema de Recomendação de artigos científicos
- Algoritmo de recomendações
- Protocolo de avaliação online e offline com gabarito de coautoria

Limitações

- Impacto por *cold start*
- Cobertura parcial do fator de prestígio: teto de recall no modelo multiplicativo
- Qualidade percebida ainda modesta (Likert média < 3)
- Word2Vec estático, não contextual

Trabalhos Futuros

- Análise de resumos e texto com SciBERT
- Tratar a ausência de prestígio como dado faltante
- Escalabilidade do ecossistema
- Ampliação da avaliação com usuários

Referências

KIM, J. K.; CHOI, I.-Y.; LI, Q. Customer satisfaction of recommender system: Examining accuracy and diversity in several types of recommendation approaches. Sustainability, v. 13, p. 6165, May 2021. Disponível em: <https://www.researchgate.net/publication/351994770>

BROUWER, W.; HOLLENBACH, M. Search engine optimization for scientific publications: How one can find your needle in the haystack. United European Gastroenterology Journal, v. 10, p. 906 – 908, 2022. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/36190015/>

ELSEVIER; SCIENCE, S. A. Trust in Research Report. 2019. Disponível em: https://web.archive.org/web/20230223060917/https://www.elsevier.com/_data/assets/pdf_file/0011/908435/Trust_evidence_report_summary_Final.pdf

Referências

- WANG, D. et al. A content-based recommender system for computer science publications. Knowledge-Based Systems, v. 157, p. 1–9, 2018. ISSN 0950-7051
- KREUTZ, C.; SCHENKEL, R. Scientific paper recommendation systems: a literature review of recent publications. International Journal on Digital Libraries, Springer, p. 335–369, 2022. Disponível em: <https://doi.org/10.1007/s00799-022-00339-w>.
- YU, J. Enhancing recommender systems with self-supervised learning. Tese (Doutorado) — School of Information Technology and Electrical Engineering - The University of Queensland, 2023. Disponível em: <https://doi.org/10.14264/9b4b38b>.

Referências

FIRE, M.; GUESTIN, C. Over-optimization of academic publishing metrics: Observing goodhart's law in action. GigaScience, v. 8, 06 2019. Disponível em:

<https://pubmed.ncbi.nlm.nih.gov/31144712/>

BURKE, R. Hybrid recommender systems: Survey and experiments. User Modeling and User-Adapted Interaction, Kluwer Academic Publishers, Hingham, MA, USA, v. 12, n. 4, p. 331–370, nov. 2002. ISSN 0924-1868. Disponível em:

<http://dx.doi.org/10.1023/A:1021240730564>

RICCI, F. et al. (Ed.). Recommender Systems Handbook. Springer, 2011. ISBN 978-0-387-85819-7. Disponível em: <https://www.springerlink.com/content/978-0-387-85819-7>

Referências

- LI, Y. et al. Enhancing systematic literature reviews with generative artificial intelligence: development, applications, and performance evaluation. J. Am. Med. Inform. Assoc., v. 32, n. 4, p. 616–625, abr. 2025. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/40036547/>
- DECLERCQ, J.; POPPEL, L. van. Coding metaphors in interaction: A study protocol and reflection on validity and reliability challenges. International Journal of Qualitative Methods, v. 22, 2023. Disponível em: <https://doi.org/10.1177/16094069231164608>.



Universidade Federal da Bahia
Departamento de Ciência da Computação
Mestrado em Ciência da Computação

Obrigado!

Orientando: Lucas França Freitas
Orientador: Frederico Araujo Durão
